


I. 시계열분석의 기초

1. 시계열 자료란?

- 시간의 흐름에 따라 일정 간격으로 수집된 종단면 자료



- 용어 : ① 시점 (time point) = 어느 한 특정 점(순간)

② 시차 (time lag) = 시점 간 간격⁽²⁰⁾ ex) $t_2 - t_1 = t_2 - t_1$

1.3. 구분 및 표기 { 연속형 : 연속적 시점으로 관측, $\{y_t : 0 \leq t \leq T\}$
이산형 : 등간격의 이산적 시점으로 관측, $\{y_t : t = 1, 2, 3, \dots\}$ 또는 $y_1, y_2, \dots$

2. 시계열 자료 특징

2.1. 시계열 자료 특징 { ① 독립변수가 시간시점을 의미 $\rightarrow$ 시계열분석 = 시간변수와 상관계수분석.

(f) 시도표 (time plot) : 2차원 그림 (x: 시간, y: 측정값)

② 인접 시간(시점) 간의 자기상관 관계 (종속성) 존재 : 일정 시간 흐름 따른 데이터집합이기 때문.

$$\rightarrow \text{상관계수 } \rho_{xy} = \frac{\text{Cov}(x, y)}{\sigma_x \cdot \sigma_y}$$

ii) 자기상관계수 = 현 시점 & n차 지연 자료 간 상관관계 수치화

2.3. 시계열자료 4가지 구성요인

(f) 시계열모형 구성요인 간 결합방식 따라

i) 추세요인 (Trend factor)

① Additive : $Z_t = T_t + S_t + C_t + I_t$

- 시계열의 장기적 (20y) 변화 추세

② Multiplicative : $Z_t = T_t \cdot S_t \cdot C_t \cdot I_t$

- 증감 경향이 선형/함수관계로 나타낼 수 있는지 찾는 것

ii) 순환요인 (Cycle factor)

ex) 경기 순환 (biz. cycle)

- 주기 (2y ≤ 10y) 변화요인

- 함수 구하기 쉽지 않음

iii) 계절요인 (Seasonal factor)

- 단기 (= 1y, 12m) 변동요인으로 분기/월별 자료에서 주로 나타남.

iv) 불규칙요인 (Irregular factor)

- 위 3가지 외 변동요인으로 시계열 내 "Noise" 에 해당

- 불규칙 변동이 많으면 예측의 신뢰성 떨어짐

3. 시계열자료 분석

- 3.1. 분석 목적
- ① 자료의 기술 (description) : 시도표, ACF 등 사용해 특성 파악
 - ② 미래 예측 (prediction / forecasting) : 가장 중요한 목적으로 어떤 자료나 과거 관찰값들의 변화 패턴과 비슷하게 앞으로 변할 것 이란 전제 하에서 후시점 값 예측
 - ③ 설명 (explanation) : 형태 설명 위한 과학적 노력 ex biz cycle 실증
 - ④ 제어 (control) : 원하는 목표 부양하도록 유도 ex 원화적 통화정책

- 3.2. 적용분야 별 접근법
- 1) 시간 영역 : ACF 등 이용해 상관정도 파악 가능한 시간함수로 모델링 → AC, 상호상관분석, 시계열회귀분석, 지수평활, ARIMA 모델 사용
 - 2) 진동/주파수 영역 : 스펙트럼 변환 ... 산공이 사용...

- 3.3. 시계열 자료 개수(변수) 따른 분석법
- a) 단변량 (univariate T/A) : 특정 하나 시계열 데이터 이용한 분석
 - b) 다변량 (Multivariate T/A) : 2개 이상 시계열 데이터 이용한 분석

II. 평활법 (Smoothing Method)

Ques 1 What is Smoothing Method?

- 과거 & 현재 자료 smoothing 시켜 미래값 예측
- 자료들 간 상관관계 고려 X
- 종류 : a) 목적법 (eye-measurement) b) 이동평균법 (MA) c) 지수평활법 (Exp. Smoothing) d) 시계열회귀분석

1. 이동평균법

1.1. 단순이동평균법 (MA)

- 수평적 패턴 (horizontal pattern), 즉 시간 경과 따라 평균 수준이 변하지 않는 시계열에 유용
- 시계열 $\{Z_t\}$, 시점 n 에서 $m-1$ 간 MA: $MA_n = \frac{1}{m} \sum_{t=n-m+1}^n Z_t$
- 예측 : $\hat{Z}_{t+1} = F_{t+1} = MA_t$
- ex) $Z_t = c + e_t$ where $e_t \stackrel{iid}{\sim} (0, \sigma^2)$, $Z_{1:n}$ given.

$$\rightarrow \text{WTF } Z_{n+m} = c + e_{n+m}$$

$$\rightarrow E[Z_{n+m} | Z_{1:n}] = E[c + e_{n+m}] = c$$

$$\Rightarrow \hat{Z}_{n+m} = \hat{c}$$

But c is unknown, so we have to estimate c (using MA) :

$$\hat{c} = MA_t = \frac{1}{m} (Z_{t-m+1} + \dots + Z_t)$$

$$(\because E[MA_t] = \frac{1}{m} \times mc = c, MA_t \text{ is unbiased estimator of } c)$$

- Then how do choose the # of data, m ?

We can use MSE where $MSE(m) = \frac{1}{n} \sum (Z_t - F_t)^2$

$$\rightarrow \hat{m} = \underset{m}{\text{Argmin}} MSE(m)$$

1.2. 이중 (선형) 이동평균법

- linear trend pattern 있는 시계열에 유용

$$- MA'_n = \frac{1}{m} \sum_{t=n-m+1}^n MA_t$$

- ex) $X_t = c + bt + e_t$ where $e_t \stackrel{iid}{\sim} (0, \sigma^2)$, X_{mn} given.

$$WTF \ X_{n+l} = c + b(n+l) + e_{n+l}$$

$$\rightarrow \hat{X}_{n+l} = E[X_{n+l} | X_{mn}] = E[c + b(n+l) + e_{n+l}] = \hat{c} + \hat{b}(n+l)$$

$\rightarrow$ WTF unbiased estimator of $c + bt$

$$E[MA_t] = E\left[\frac{1}{m} (X_{t-m+1} + \dots + X_t)\right]$$

$$= E\left[\frac{1}{m} (c + b(t-m+1) + e_{t-m+1}) + \dots + (c + bt + e_t)\right]$$

$$= E\left[\frac{1}{m} \left\{ mc + b\left(mt - \frac{m(m-1)}{2}\right) \right\} + \frac{1}{m} \sum_{t=m+1}^t E(e_t)\right]$$

$$= c + bt - \frac{m-1}{2} b \quad \exists \text{ bias}$$

$$E[MA'_t] = E\left[\frac{1}{m} (MA_{t-m+1} + \dots + MA_t)\right]$$

$$= \frac{1}{m} E\left[\left(c + b(t-m+1) - \frac{m-1}{2} b\right) + \dots + \left(c + bt - \frac{m-1}{2} b\right)\right]$$

$$= \frac{1}{m} E\left[\left(mc + b\left(mt - \frac{m(m-1)}{2}\right) - \frac{m(m-1)}{2} b\right)\right]$$

$$= c + bt - (m-1)b \quad \exists \text{ bias}$$

$$\rightarrow E[MA_t] - E[MA'_t] = \frac{m-1}{2} b = E[X_t] - E[MA_t]$$

$$\Rightarrow \hat{b} = \frac{2}{m-1} (MA_t - MA'_t), \quad \hat{c} = 2MA_t - MA'_t - \hat{b}t \quad \text{is unbiased estimators.}$$

$$\Rightarrow \hat{X}_{n+l} = \hat{c} + \hat{b}(n+l)$$

$$\Rightarrow \hat{F}_{n+l} = \hat{c} + \hat{b}(n+l) = (2MA_t - MA'_t) + \frac{2}{m-1} (MA_t - MA'_t) \cdot l$$

2. 지수평활법

Pro) ① 이전과 달리 전체 데이터 사용하되 가장 최근 데이터에 큰 가중치 주고 과거로 갈수록 가중치가 기하학적으로 감소되는

가중치 이동평균 예측기법

② 자료손실없이 전체 데이터 이용

③ 시계열 구조 변화시 변화에 쉽게 대처가능

④ 정확도 높아 단기 예측에 많이 이용

2.1. 단순 지수평활법 by Charles C. Holt.

- 추세 및 계절성 없는 horizontal pattern 가진 시계열에 유용.

$$- Z_t = a + e_t \quad \text{where } e_t \stackrel{iid}{\sim} (0, \sigma^2)$$

$$\rightarrow \{Z_t\}, \text{ 시점 } n \text{에서의 지수평활값} : \boxed{J_n = \alpha Z_n + (1-\alpha) J_{n-1}} \quad \alpha: \text{평활상수, } \in (0, 1)$$

$$\rightarrow \hat{F}_{n+1} = J_n$$

$$- J_t = \alpha Z_n + (1-\alpha) J_{n-1} = \alpha Z_n + (1-\alpha) \{Z_{n-1} + (1-\alpha) J_{n-2}\} = \dots = \alpha \sum_{j=0}^{t-1} (1-\alpha)^j Z_{t-j} + (1-\alpha)^t J_0$$

$\rightarrow$ Prob) How to choose J_0 & α ?

$$\textcircled{1} J_0 \text{ (초기 평활값)} \begin{cases} \text{Brown et. al (1976)} : \bar{Z} = \frac{1}{n} \sum_{t=1}^n Z_t \quad (n=6 \text{ or } n=T/2) \\ \text{Makridakis & - (1978)} : Z_1 \end{cases}$$

$$\text{MSE} \quad \textcircled{2} \alpha = \underset{\alpha}{\text{Argmin}} \sum_1^n (Z_t - J_{t-1})^2 = 0.05 \sim 0.3 \text{ (Brown, 1962)}$$

2.2. 선형지수평활법 by Brown, Holt

- 선형 추세성 있는 시계열에 적합: $Z_t = a + bt + e_t$ where $e_t \stackrel{iid}{\sim} (0, \sigma^2)$

2.2.1. Brown의 이중지수평활법

- 기존 지수평활값: $J_n = \alpha Z_n + (1-\alpha) J_{n-1}$

→ 이중지수평활값: $J'_n = \alpha J_n + (1-\alpha) J'_{n-1}$

- ex) $Z_t = a + bt + e_t$ where $e_t \stackrel{iid}{\sim} (0, \sigma^2)$

$$J_n = \alpha Z_n + (1-\alpha) J_n \cong \alpha \sum_0^{n-1} (1-\alpha)^t Z_{n-t} + (1-\alpha)^n J_0 \quad \text{--- ①}$$

$$\rightarrow \mathbb{E}[J_t] \cong \mathbb{E}[\alpha \sum_0^{n-1} (1-\alpha)^t Z_{n-t}] = \alpha \sum_0^{n-1} (1-\alpha)^t \{a + b(n-t)\} = a + bn - \alpha b \sum_0^{n-1} (1-\alpha)^t t \quad \text{--- ②}$$

$$= a + bn - \left(\frac{1-\alpha}{\alpha} b \right) \exists \text{ bias}$$

$$J'_n = \alpha J_n + (1-\alpha) J'_{n-1} = \alpha \sum_0^{n-1} (1-\alpha)^t J_{n-t} + (1-\alpha)^n J'_0 \cong \alpha \sum_0^{n-1} (1-\alpha)^t J_{n-t} \quad \text{--- ③}$$

$$\rightarrow \mathbb{E}[J'_n] \cong \alpha \sum_0^{n-1} (1-\alpha)^t \mathbb{E}[J_{n-t}]$$

$$\cong \alpha \sum_0^{n-1} (1-\alpha)^t \{a + b(n-t) - \frac{1-\alpha}{\alpha} b\} = a + bn - 2 \left(\frac{1-\alpha}{\alpha} b \right) \exists \text{ bias} \quad \text{--- ④}$$

$$\textcircled{1} - \textcircled{4} : b \cong \frac{1-\alpha}{\alpha} \mathbb{E}[J_n - J'_n] \Rightarrow \hat{b} = \frac{1-\alpha}{\alpha} (J_n - J'_n)$$

$$\textcircled{2} \text{ 정리} : a + bn \cong \mathbb{E}[J_n + \frac{1-\alpha}{\alpha} b] \Rightarrow \hat{a} + \hat{b}n \cong J_n + \frac{1-\alpha}{\alpha} b = 2J_n - J'_n$$

$$\text{since } F_{t+1} = Z_{t+1} = \mathbb{E}[Z_{t+1} | Z_{1:n}] = a + b(t+1)$$

$$\rightarrow \hat{F}_{t+1} = \hat{a} + \hat{b}(t+1) = (2S_t - S'_t) + 1\hat{b}$$

$$\rightarrow \hat{F}_{t+l} = \hat{a} + \hat{b}(t+l) = (2S_t - S'_t) + l\hat{b} = (2S_t - S'_t) - \underbrace{\frac{\alpha}{1-\alpha} (S_n - S'_n) l}_{\text{???}}$$

2.2.2. Holt의 선형지수평활법

- 이중지수평활값 사용 않는 것 제외하면 Brown과 유사

- 추세 먼저 추정 후 그것 이용해 예측하는 방법. 2개 α & 2개 평활상수 포함.

- $Z_t = a + bt + e_t$ where $e_t \stackrel{iid}{\sim} (0, \sigma^2)$

$$\text{- 자료의 평활} : \hat{a}(t) = \alpha Z_{t-1} + (1-\alpha) [\hat{a}(t-1) + \hat{b}(t-1)]$$

$$\text{- 추세의 평활} : \hat{b}(t) = \beta [\hat{a}(t) - \hat{a}(t-1)] + (1-\beta) \hat{b}(t-1) \text{ where } 0 \leq \alpha, \beta \leq 1$$

$$\text{- 초기값} : \hat{a}(1) = Z_1, \hat{b}(1) = Z_2 - Z_1 \text{ or } \frac{(Z_2 - Z_1) + (Z_3 - Z_2)}{2} = 0.03 \sim 0.16 \text{ (Brown 제안)}$$

$$\text{- 예측} : \hat{F}_{t+l} = \hat{a}(t) + \hat{b}(t)l$$

3. 계절지수평활법 : 추세 & 계절성 있는 시계열에 적합!

Bgnd) 1. 월 / 분기별 자료는 계절성 有 → 고려한 모형 필요

2. 두 가지 형태 - 가법: 시간 따른 계절적 진폭 크기 일정

승법: 계절적 진폭 크기가 추세 의해 결정되는 평균에 비례해 점차적 증가 or 감소

3.1. 윈터스 모형 (Winters, 1960)

1) 승법적 계절지수평활법 : 선형추세선에 승법적 변동이 있을 때

$$T_t \cdot S_t \cdot \varepsilon_t = (a + bt) \times S_t \times \varepsilon_t \quad \text{where } \varepsilon_t \stackrel{iid}{\sim} (0, \sigma^2)$$

- $\{Z_t\}$ 에서 수평, 추세, 계절성을 각각 갱신

$$\text{수평성분} : a_t = \alpha \frac{Z_t}{S_{t-1}} + (1-\alpha) [a_{t-1} + b_{t-1}]$$

$$\text{추세성분} : b_t = \beta (a_t - a_{t-1}) + (1-\beta) b_{t-1}$$

$$\text{계절성분} : S_t = \gamma \frac{Z_t}{a_t} + (1-\gamma) S_{t-1}$$

($\alpha, \beta, \gamma \in (0, 1)$, 1: 계절주기)

from Holt.
선형지수평활식.

$$(\text{초기값} : a_0 = \bar{Z}_1 - \frac{1}{2}b_0, b_0 = \frac{\bar{Z}_m - \bar{Z}_1}{(m-1)1}, S_0 = \bar{S}_0 \left[\frac{1}{\sum_{t=1}^m \bar{S}_t} \right], \bar{S}_t = \frac{1}{m} \sum_{k=0}^{m-1} S_{t+k})$$

($\bar{Z}_i$ ($1 \leq i \leq m$)은 i번째 연도 시계열 평균)

- 예측 : $F_{n+l} = (a_n + b_n \cdot l) S_{n+l-1}$ ($l=1, 2, \dots, L$)

- 평활상수 : Argmin MSE

2) 가법적 계절지수평활법 : 선형추세선에 가법적 계절변동 있을 때

- $\{Z_t\}$ 에서 수평, 추세, 계절성을 각각 갱신

$$\text{수평성분} : a_t = \alpha (Z_t - S_{t-1}) + (1-\alpha) [a_{t-1} + b_{t-1}]$$

$$\text{추세성분} : b_t = \beta (a_t - a_{t-1}) + (1-\beta) b_{t-1}$$

$$\text{계절성분} : S_t = \gamma (Z_t - a_t) + (1-\gamma) S_{t-1}$$

- 예측 : $F_{n+l} = (a_n + b_n \cdot l) + S_{n+l-1}$ ($l=1, 2, \dots, L$)

III. 확률적 시계열분석의 기초

1. 확률과정과 정상성

1. 확률과정과 실현값

Def) 확률과정 : 시점 t 에서의 시계열 Z_t 가 하나의 확률변수 (r.v.)라 하면 이런 r.v.의 집합 :

$\{Z_t : t \in T\}$ 를 확률과정이라 한다.

→ t 가 시간 일때 이 확률과정을 시계열과정 / 시계열모형이라 한다.

≠ 실현값 z_t : 모집단으로부터 각 시점에서 얻어진 표본

1.2. 정상성 (stationarity)

- Prob) 무한개 관찰치 → 시계열 모형 → 분석의 단순화 필요!

- 가장 중요한 가정 : 시간의 변화에도 확률적 성질 (적률, 결합확률분포 등)이 변하지 않는다는 것 $\Leftrightarrow$ 정상성 가정

- Def) 강정상성 (strongly stationary)


$\forall \{Z_t : t \geq 1\}, \forall t_1, \dots, t_n \in \mathbb{N}, \forall k$ 대해 결합밀도함수가

$$f(Z_{t_1}, \dots, Z_{t_n}) = f(Z_{t_1+k}, \dots, Z_{t_n+k})$$

을 만족하면 $\{Z_t\}$ 를 강정상 또는 정상시계열이라 한다.

(cf) 정상성 가정은 본래 확률과정에 관한 것이지만 편의상 확률과정 실현값인 시계열이 정상성을 갖는다고 취급하자.


(second-order stationary, Cov. stationary)
 - Def) 약정상성: 시계열 $\{Z_t : t \geq 1\}$ 대해



① $E[Z_t] = \mu (=0), \forall t$: 평균이 $\mu=0$ (상수)로 일정. 즉, 시간이 흘러도 평균이 일정, 시간 t 에 종속 X)
 (first moment estimation)

② $Var(Z_t) = \gamma(0) = \sigma^2 < \infty, \forall t$: 분산이 σ^2 이며 유한의 값, 시간에 종속 X
 (the second moment estimation)

③ $Cov(Z_t, Z_{t+k}) = E[(Z_t - E[Z_t])(Z_{t+k} - E[Z_{t+k}])] = \gamma(k), \forall t, j(t+k)$
 : 두 시점 간 자기공분산은 시점 t 와는 무관, 시차 k 에만 의존 (the cross moment estimation)
 을 만족하면 (약) 정상성 가정을 만족한다고 하자.



- (cf) 강정상성 & 약정상성 : ① 강 $\leftrightarrow$ 약
 $Z_t \sim N$ 이면 예외적으로 성립.

② 많은 시계열이론은 정상성에 기반하므로 만족하지 않으면 차분, 분산안정화 등 만족하게 적절히 변환시켜줘야 한다.

1.3. 중요한 이유

- a) 과적합 예방 : 기존 2n개 모수 추정 $\rightarrow$ 2개 모수 추정 $\Rightarrow$ 과적합 발생 확률 $\downarrow$
- b) 예측가능성 및 정확성 : 분산 안정화 등으로 예측값이 튀지 않고 보다 안정적이고 정확한 예측 가능
- c) 자기상관구조 예측 가능 : 자기공분산이 시차 k 에만 의존 $\rightarrow$ ACF, PACF 등으로 모형 식별 가능.

2. 자기공분산함수와 자기상관함수

(X편차) $\times$ (Y편차)

Rev) Cov : 평균을 중심으로 함께 변하는 정도, $Cov(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$
 $\xrightarrow{\text{scaling}} \rho_{X,Y} = \frac{Cov(X, Y)}{\sqrt{Var(X)} \sqrt{Var(Y)}}, \rho_{X,Y} \in [-1, 1]$

2.1. 자기공분산함수

정상시계열 $\{Z_t\}$ 에서 $E[Z_t] = E[Z_{t+k}] = \mu = 0$ 이라 할 때,

Def) 자기공분산함수 γ_k (k : 시차)

$$\gamma_k = Cov(Z_t, Z_{t+k}) = E[(Z_t - \mu)(Z_{t+k} - \mu)] = E[Z_t Z_{t+k}] - \mu^2 = E[Z_t Z_{t+k}]$$


Prop) ① $\gamma_0 = Var(Z_t)$ ② $\gamma_k = \gamma_{-k}$ ($k=0$ 에 대해 대칭인 함수)

2.2. 자기상관함수 (ACF)

- 시간에 따른 값들이 얼마나 밀접하게 관련되어있는지 나타내는 지표로 시차에 따른 상관관계를 측정
- 자기상관이 (시차가 커져도) 오래 지속되면 비정상 시계열일 가능성이 높으며, 차분이 필요하다는 신호가 된다

- 시계열 유형)	AC	예측 가능성	Description
White Noise	X	불가능	완전 무작위
Stationary	O	가능	AR, MA 적함
Non-stationary (변환전)	O	어려움	예측 어렵 (추세)
" (변환후)	O	가능	차분 후 예측 가능

- Def) $\rho_k = \frac{\text{Cov}(Z_t, Z_{t+k})}{\sqrt{\text{Var}(Z_t)} \sqrt{\text{Var}(Z_{t+k})}} = \frac{\text{Cov}(Z_t, Z_{t+k})}{\text{Var}(Z_t)} = \frac{\gamma_k}{\gamma_0} \rightarrow \textcircled{1} \rho_0 = 1$
 $\textcircled{2} \rho_k = \rho_{-k}$



- Box-Jenkins 모형 통해 ACF 특성을 이용해 추정을 하게 되는데 이를 $\backslash$ ACF라 한다 :

$$\gamma_k = \hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\gamma}_0} = \frac{\sum_{i=1}^{n-k} (Z_t - \bar{Z})(Z_{t+k} - \bar{Z})}{\sum_{i=1}^{n-k} (Z_t - \bar{Z})^2} \xrightarrow{n \rightarrow \infty} \rho_k$$

이때, $n \geq 30, \rho_k = 0 \ (k > m)$ 이면

$$\text{Var}(\gamma_k) = \text{Var}(\hat{\rho}_k) \approx \frac{1}{n} (1 + 2\rho_1^2 + 2\rho_2^2 + \dots + 2\rho_m^2)$$

따라서, $S_{\gamma_k} = \text{SE}(\hat{\rho}_k) = \sqrt{\frac{1}{n} (1 + 2\rho_1^2 + 2\rho_2^2 + \dots + 2\rho_m^2)}$

3. 편자기상관함수 (PACF)

3.1. PACF

- 특정 시차에서 상관관계 측정하되 **중간 영향 제거한 순수 상관관계**를 의미.

- ACF ρ_{00b} 시차 길어질수록 중간에 영향을 주는 다른 시차의 영향을 받음

- Def) $\phi_{kk} = \text{Cov}(Z_t, Z_{t+k} \setminus Z_{t+1}, \dots, Z_{t+k-1})$ } 시차 k 대한 함수 : 편자기상관함수
 ↓
 고정된 k 대해 : 편자기상관계수

- ex) 정상시계열 $\{Z_t\}$ 대해

$$\begin{aligned} \mathbb{E}[Z_{t+k}] & \begin{cases} Z_{t+k} = \phi_{k1} Z_{t+k-1} + \phi_{k2} Z_{t+k-2} + \dots + \phi_{kk} Z_t + \varepsilon_{t+k} \quad (\phi_{kj} : j \text{ 번째 회귀계수}, \varepsilon_{t+k} : \text{서로 종속되지 않은 정규오차항}) \\ \gamma_j = \phi_{k1} \gamma_{j-1} + \phi_{k2} \gamma_{j-2} + \dots + \phi_{kk} \gamma_{j-k} \\ \rho_j = \phi_{k1} \rho_{j-1} + \phi_{k2} \rho_{j-2} + \dots + \phi_{kk} \rho_{j-k} \end{cases} \\ j=1 \sim k & \begin{cases} \begin{pmatrix} \rho_0 & \dots & \rho_{k-1} \\ \vdots & \ddots & \vdots \\ \rho_{k-1} & \dots & \rho_0 \end{pmatrix} \begin{pmatrix} \phi_{k1} \\ \phi_{k2} \\ \vdots \\ \phi_{kk} \end{pmatrix} = \begin{pmatrix} \rho_1 \\ \vdots \\ \rho_k \end{pmatrix} \quad \text{: Yule-Walker eqt.} \end{cases} \\ \text{Cramer's Rule.} & \begin{cases} \phi_{kk} = \frac{\begin{vmatrix} \rho_1 & \rho_2 & \dots & \rho_{k-2} & \rho_{k-1} \\ \rho_2 & \rho_3 & \dots & \rho_{k-1} & \rho_k \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \rho_{k-1} & \rho_k & \dots & \rho_{k-1} & \rho_k \end{vmatrix}}{\begin{vmatrix} \rho_1 & \rho_2 & \dots & \rho_{k-1} & 1 \\ \rho_2 & \rho_3 & \dots & \rho_k & \rho_1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \rho_{k-1} & \rho_k & \dots & \rho_{k-1} & \rho_k \end{vmatrix}} \end{cases} \\ & \text{Var}(\hat{\phi}_{kk}) \xrightarrow{H_0: \phi_{kk}=0} 1/n \quad \text{CI: } \hat{\phi}_{kk} \pm 1.96 \sqrt{\frac{1}{n}} \end{aligned}$$

4. 연산자

1) 후향 연산자 : $BX_t = X_{t-1}, \dots \Rightarrow B^k X_t = X_{t-k}, (1-B)X_t = X_t - X_{t-1}$
 Backshift

2) 전향 연산자 : $FX_t = X_{t+1}, \dots \Rightarrow F^k X_t = X_{t+k}, (1-F)X_t = X_t - X_{t+1}$
 Forward shift

3) 차분 연산자 : $\nabla X_t = (1-B)X_t \dots \Rightarrow \nabla^d X_t = (1-B)^d X_t$, 추세변동 제거 목적
 Diff-

ex) $X_t = \beta_0 + \beta_1 t + \varepsilon_t \ (\varepsilon_t \stackrel{iid}{\sim} (0, 1)) \rightarrow \nabla X_t = \beta_1 + \nabla \varepsilon_t$: 비정상 원인이면 추세 β_0 제거됨
 1차 차분 : 선형 추세 제거, 2차 차분 : 곡선 추세 제거

4) 계절 연산자 : $\nabla_s X_t = (1-B^s)X_t \dots \Rightarrow \nabla_s^p X_t = (1-B^s)^p X_t$ (cf) 계절차분 횟수 표기 D
 Seasonal Diff- ($s=12$ or 4) $\neq$ 일반차분 횟수 표기 d

ρ_{00b} } a) 과대차분 : 필요이상으로 차분해 변동성 커짐 $\rightarrow$ ① 시계열이 진동/잡음처럼 보임 ② ACF/PPCF 음수 상관 ③ 정보손실 및 모델복잡
 b) 과소차분 : 추세 및 단위근 남아있음 $\rightarrow$ ① ACF 천천히 감소 ② 평균 밀집 X, 위아래로 헤엄 ③ 잔차가 비정상적이라 예측 정확도 ↓
 ($\approx$ or ω)

$\rightarrow$ 둘 다 문제지만 과대차분이 더 안 좋다

5. 백색잡음과정과 확률보행과정

5.1. White Noise Process

- Def) 확률과정 $\{ \varepsilon_t : t = 0, \pm 1, \pm 2, \dots \}$ $\stackrel{iid}{\sim} (\mu_\varepsilon (=0), \sigma_\varepsilon^2 < \infty)$, $\gamma_k = \text{Cov}(\varepsilon_t, \varepsilon_{t+k}) = 0 \quad \forall k \neq 0$

→ 정의에 따라 (시간의존 X) W.N.은 항상 정상성을 갖는다.

→ iid 이므로 예측이 불가능 (→ W.N. = 시계열 data - 시계열적 root)

→ 시계열 오차 (=관측-예측) 가 W.N. 이면 매우 적합하게 설계됐다고 판단. (⇒ 모델 적합성 판단에 유용!)

$$\gamma_k = \begin{cases} \sigma_\varepsilon^2 & (k=0) \\ 0 & (k \neq 0) \end{cases}, \text{ACF } \rho_k = \begin{cases} 1 & (k=0) \\ 0 & (k \neq 0) \end{cases}, \text{PACF } \phi_{kk} = \begin{cases} 1 & (k=0) \\ 0 & (k \neq 0) \end{cases}$$

- 시계열 모형 수립에 매우 중요.. 보통 오차항 $\sim$ W.N. 가정.

5.2. Random Walk Process

- 시간에 따라 평균과 분산이 변하는 비정상적 데이터

- Def) $\varepsilon_t \sim \text{W.N.}$ if $z_t = z_{t-1} + \varepsilon_t \Leftrightarrow z_t = \sum_{i=1}^t \varepsilon_i \quad (t=1, 2, \dots)$ ($z_0=0$ 가정)

- Prop) ① $E[z_t] = 0$

$$\textcircled{2} \text{Var}(z_t) = t \sigma_\varepsilon^2 \quad (\rightarrow \text{비정상 시계열})$$

$$\textcircled{3} \gamma_k = \text{Cov}(z_t, z_{t-k}) = \text{Cov}\left(\sum_{i=1}^t \varepsilon_i, \sum_{i=1}^{t-k} \varepsilon_i\right) = \text{Var}(z_{t-k}) = (t-k) \sigma_\varepsilon^2$$

⇒ $\text{Var}(z_t), \gamma_k$ 가 t 대한 함수이므로 비정상 시계열

$$\text{ACF } \rho_k = \frac{(t-k) \sigma_\varepsilon^2}{\sqrt{t \sigma_\varepsilon^2 \cdot t \sigma_\varepsilon^2}} = \sqrt{\frac{t-k}{t}} \approx 1 \text{ as } t \rightarrow \infty$$

$$\text{PACF } \phi_{kk} = \begin{cases} \approx 1 & (k=0) \\ 0 & (k \neq 0) \end{cases}$$

- $\nabla z_t = \varepsilon_t \sim \text{W.N.}$ 이되어 정상성을 갖는다.

- ex) $z_t = \underset{\text{drift}}{\alpha} + z_{t-1} + \varepsilon_t$: 확률적 추세(예측 불가능한 체계적 패턴) 갖는 시계열로 $\alpha > 0$ 이면 우상향, $\alpha < 0$ 이면 우하향.

IV. 정상 시계열 모형

Proc) ARMA Model (Box-Jenkins Model)

- Bgrnd) 정상성 가정하는데 어느정도 멀리 있는 과거 관측치까지 이용? 가중치 사용?

- AR(p) : $z_t = \phi_1 z_{t-1} + \dots + \phi_p z_{t-p} + a_t$ where $a_t \stackrel{iid}{\sim} \text{W.N.} (N(0, \sigma^2))$

- MA(q) : $z_t = a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q}$ where $a_t \stackrel{iid}{\sim} \text{W.N.} (N(0, \sigma^2))$

- ARMA(p, q) : $z_t = \phi_1 z_{t-1} + \dots + \phi_p z_{t-p} + a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q}$ where $a_t \stackrel{iid}{\sim} \text{W.N.} (N(0, \sigma^2))$

1. AR 모형

- AR : $z_t = \phi_1 z_{t-1} + \dots + a_t \quad (a_t \stackrel{iid}{\sim} \text{W.N.})$

- AR(p) : $z_t = \phi_1 z_{t-1} + \dots + \phi_p z_{t-p} + a_t$ where $a_t \stackrel{iid}{\sim} \text{W.N.} (N(0, \sigma^2))$

- (ntf) 시계열 현재 가치 = 과거 가치 + 확률적 충격

- Cf) AR & 회귀모형 차이

① AR은 I.V. 간 독립성 가정 X

② AR은 I.V. 개수가 모형 추정 과정에서 지속적으로 결정

1.1. AR(1)

$$- Z_t = \phi_1 Z_{t-1} + \varepsilon_t \quad \text{or} \quad (1 - \phi_1 B) Z_t = \varepsilon_t \stackrel{iid}{\sim} W.N.(0, \sigma_\varepsilon^2), \quad \text{Cov}(\varepsilon_t, Z_{t-k}) = 0, \quad \text{Cov}(\varepsilon_t, Z_t) \neq 0, \quad \forall k > 0$$

- ϕ_1 은 추정하는데, $\phi_1 = 1$ 일때 σ_ε w. ($\phi_1 = 1$ 이면 잘못된 모형)

- α 포함가능 but 통상 평균을 0으로 가정해 생략.

$$- Z_t = \phi_1 Z_{t-1} + \varepsilon_t = \phi_1 (\phi_1 Z_{t-2} + \varepsilon_{t-1}) + \varepsilon_t = \dots = \phi_1^k Z_{t-k} + \sum_{i=0}^{k-1} \phi_1^i \varepsilon_{t-i} \quad : \text{백색잡음의 가중선형결합}$$

$$- P_{oop}) \quad ① E[Z_t] = 0$$

$$② \text{Var}(Z_t) = \gamma_0 = \frac{\sigma_\varepsilon^2}{1 - \phi_1^2} \quad (= \phi_1^2 \text{Var}(Z_{t-1}) + \overbrace{2\phi_1 \text{Cov}(Z_{t-1}, \varepsilon_t)}^{\rightarrow 0} + \text{Var}(\varepsilon_t))$$

$$\star \quad ③ \gamma_k = \phi_1^k \cdot \frac{\sigma_\varepsilon^2}{1 - \phi_1^2} \quad (= E[Z_t Z_{t-k}] = \phi_1^k E[Z_{t-k} Z_t] + \sum_{i=0}^{k-1} \phi_1^i E[Z_{t-k} \varepsilon_{t-i}])$$


$$④ \text{ACF} : \rho_k = \phi_1^k \quad (\hat{S}_{\rho_k} \cong \sqrt{\frac{1}{n}(1 + 2\hat{\rho}_1^2 + \dots + 2\hat{\rho}_{k-1}^2)})$$

$$⑤ \text{PACF} : \phi_{11} = \phi_1, \phi_{kk} = 0 \quad (k \geq 2) \quad (\hat{S}_{\phi_{kk}} = \sqrt{\frac{1}{n}})$$

- ϕ_1 의 범위 : ① $\phi_1 \neq 1$: NOT σ_ε w.

$$② \text{Var}(Z_t) > 0 \rightarrow |\phi_1| < 1 \rightarrow Z_t = (1 - \phi_1 B)^{-1} \varepsilon_t = (1 + \phi_1 B + \dots) \varepsilon_t = \varepsilon_t + \phi_1 \varepsilon_{t-1} + \dots : W.N.의 가중선형결합$$

$\therefore$ AR(1)이 정상성을 만족하기 위한 조건은 $|\phi_1| < 1$ 이다.



1.2. AR(2)

$$- Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \varepsilon_t \quad \text{or} \quad (1 - \phi_1 B - \phi_2 B^2) Z_t = \varepsilon_t \stackrel{iid}{\sim} W.N.(0, \sigma_\varepsilon^2), \quad \text{Cov}(\varepsilon_t, Z_{t-k}) = 0, \quad \text{Cov}(\varepsilon_t, Z_t) \neq 0, \quad \forall k > 0$$

- P_{oop} (Z_t 가 정상시계열이란 가정 하에)

$$① E[Z_t] = 0$$

$$② \text{Var}(Z_t) = \gamma_0 = \frac{(1 - \phi_2) \sigma_\varepsilon^2}{(1 + \phi_2)(1 - \phi_1 - \phi_2)(1 + \phi_1 - \phi_2)}$$

$$\star \quad ③ \gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2}$$

$$④ \text{ACF} : \rho_0 = 1, \rho_1 = \frac{\phi_1}{1 - \phi_2}, \rho_2 = \frac{\phi_1^2}{1 - \phi_2} + \phi_2, \dots$$


$$⑤ \text{PACF} : \phi_{11} = \rho_1 = \frac{\phi_1}{1 - \phi_2}, \phi_{22} = \phi_2, \phi_{kk} = 0 \quad (k \geq 3)$$

- ϕ_1, ϕ_2 의 범위 : $\text{Var}(Z_t) = \gamma_0 > 0 \Leftrightarrow \dots \phi_1 + \phi_2 < 1, \phi_2 - \phi_1 < 1, -1 < \phi_2 < 1$

- 정상성 조건 : 특성방정식의 모든 근의 절댓값이 1보다 커야함. ($1 - \phi_1 B - \phi_2 B^2 = 0$)

$$\rightarrow \dots -1 < \phi_2 < 1, \phi_1 + \phi_2 < 1, \phi_2 - \phi_1 < 1$$

Cf) 특성방정식 $\phi(B) = 0$ 의 두 근을 B_1, B_2 라 할 때 $|B_1| > 1, |B_2| > 1$ 일때 AR(2)는 정상화될과정을 따른다.



1.3. AR(p)

$$- Z_t = \phi_1 Z_{t-1} + \dots + \phi_p Z_{t-p} + \varepsilon_t \quad \text{or} \quad (1 - \phi_1 B - \dots - \phi_p B^p) Z_t = \varepsilon_t \stackrel{iid}{\sim} W.N.(0, \sigma_\varepsilon^2), \quad \text{Cov}(\varepsilon_t, Z_{t-k}) = 0, \quad \forall k > 0$$

- P_{oop} $\{Z_t\}$ 가 정상인 AR(p)이면 충분히 큰 t에 대해

$$① E[Z_t] = 0$$

$$② \text{Var}(Z_t) = \gamma_0 = \frac{\sigma_\varepsilon^2}{1 - \phi_1 \rho_1 - \dots - \phi_p \rho_p}$$

$$③ \gamma_k = \phi_1 \gamma_{k-1} + \dots + \phi_p \gamma_{k-p}$$

$$④ \text{ACF} : \rho_k = \phi_1 \rho_{k-1} + \dots + \phi_p \rho_{k-p} \quad (k > 0)$$

$$⑤ \text{PACF} : \phi_{11} = \phi_1, \phi_{22} = \frac{\phi_2 - \phi_1^2}{1 - \phi_1^2}, \dots, \phi_{kk} = 0 \quad (k \geq p+1)$$

- 정상성 조건 : 특성방정식 모든 근의 절댓값이

1보다 커야함

2. MA모형

- 시계열 Z_t 를 이전 시점 $WN, \{a_t, a_{t-1}, \dots\}$ 로 회귀시킨 모형
- 항상 정상성 만족

2.1. MA(1) Model

$$- Z_t = a_t - \theta_1 a_{t-1} \quad \text{or} \quad Z_t = (1 - \theta_1 B) a_t \sim WN(0, \sigma_a^2)$$

$$- Prop) \quad ① E[Z_t] = 0$$

$$② Var(Z_t) = (1 + \theta_1^2) \sigma_a^2$$

$$③ \gamma_k = \begin{cases} (1 + \theta_1^2) \sigma_a^2 & (k=0) \\ -\theta_1 \sigma_a^2 & (k=1) \\ 0 & (k \geq 2) \end{cases}$$

$$④ ACF: \rho_k = Cov(Z_t, Z_{t-k}) = \begin{cases} -\frac{\theta_1}{1 + \theta_1^2} & (k=1) \\ 0 & (k \geq 2) \end{cases}$$

$$⑤ PACF: \phi_{kk} = \frac{-\theta_1^k (1 - \theta_1^2)}{(1 - \theta_1^{2(k+1)})} \quad (k \geq 1)$$

- θ_1 의 범위?

: ρ_1 관찰 때 $\theta_1, \frac{1}{\theta_1}$ 대입해도 같은 값 나옴 $\rightarrow$ 유일성 문제 $\rightarrow$ 가역성 (MA가 AR로 가역될 수 있다) 제약조건이 필요

2.2. MA(2) Model

$$- Z_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} \quad \text{or} \quad Z_t = (1 - \theta_1 B - \theta_2 B^2) a_t$$

$$- Prop) \quad ① E[Z_t] = 0$$

$$② Var(Z_t) = (1 + \theta_1^2 + \theta_2^2) \sigma_a^2$$

$$③ \gamma_k = \begin{cases} (-\theta_1 + \theta_1 \theta_2) \sigma_a^2 & (k=1) \\ -\theta_2 \sigma_a^2 & (k=2) \\ 0 & (k \geq 3) \end{cases}$$

$$④ ACF: \rho_k = \begin{cases} \frac{-\theta_1(1 - \theta_2)}{1 + \theta_1^2 + \theta_2^2} & (k=1) \\ \frac{-\theta_2}{1 + \theta_1^2 + \theta_2^2} & (k=2) \\ 0 & (k \geq 3) \end{cases} \rightarrow \text{lag 3에서 절단}$$

$$⑤ PACF: \phi_{kk} = \begin{cases} \rho_1 & (k=1) \\ (\rho_2 - \rho_1^2) / (1 - \rho_1^2) & (k=2) \\ (\rho_3 - \rho_1 \rho_2 (2 - \rho_2)) / (1 - \rho_2^2 - 2\rho_1^2(1 - \rho_2)) & (k=3) \end{cases}$$

2.3. MA(q) Model

$$- Z_t = a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q} \quad \text{or} \quad Z_t = (1 - \theta_1 B - \dots - \theta_q B^q) a_t$$

$$- Prop) \quad ① E[Z_t] = 0$$

$$② Var(Z_t) = (1 + \theta_1^2 + \dots + \theta_q^2) \sigma_a^2$$

$$③ Cov(Z_t, Z_{t-k}) = \gamma_k = \begin{cases} (-\theta_k + \theta_1 \theta_{k+1} + \dots + \theta_{q-k} \theta_q) \sigma_a^2 & (k \leq q) \\ 0 & (k > q) \end{cases}$$

$$④ ACF: \rho_k = Cov(Z_t, Z_{t-k}) = \begin{cases} \frac{-\theta_k + \theta_1 \theta_{k+1} + \dots + \theta_{q-k} \theta_q}{1 + \theta_1^2 + \theta_2^2 + \theta_q^2} & (k \leq q) \\ 0 & (k > q) \end{cases} \rightarrow \text{lag } (q+1) \text{에서 절단}$$

⑤ PACF: 지수적으로 감소하는 형태

- 정리) $AR(p)$ 와 $MA(q)$ 의 쌍대성 (Duality)

$$\rightarrow AR(1) \text{ ACF} \approx MA(1) \text{ PACF}$$

그림보고 공부해야 함!

$$AR(1) \text{ PACF} \approx MA(1) \text{ ACF}$$

⋮

3. AR, MA 모형 정상성 및 가역성 조건

a) AR 모형 정상성 조건 : $AR(1) \quad |\phi_1| < 1$

$$AR(2) \quad |\phi_1 + \phi_2| < 1, |\phi_2 - \phi_1| < 1, |\phi_2| < 1$$

} $\Rightarrow AR \text{ 모형} \rightarrow MA(\infty)$ 로 표현 가능
①

$\Rightarrow$ 특성방정식 모든 근의 절대값이 1보다 커야 한다

b) MA 모형 정상성 조건 : 자체적으로 만족 (Wald Cdtn: 정상과정은 서로 무상관인 확률변수의 선형결합으로 이뤄지며, 평균/분산은 유한)
 z_t 는 서로 독립 확률변수 $\{a_t\}$ 선형결합 & 평균/분산 유한하므로 Wald Cdtn 따라 정상성 만족.

c) AR 모형 가역성 조건 : 자체적으로 충족 ($\because \phi(B)z_t = \varepsilon_t$ 로 좌변에 특성함수 존재)

d) MA 모형 가역성 조건 : $z_t = \theta(B)a_t \Leftrightarrow \theta'(B)z_t = a_t$ 표현가능해야 함. ($\Leftrightarrow MA \text{ 모형} \rightarrow AR(\infty)$ 로 표현 가능)

$\Rightarrow$ 일반적으로 특성방정식 모든 근의 절대값이 1보다 커야 한다
②

① 정상성 만족하는 $AR(p)$ 는 $MA(\infty)$ 로 쓸 수 있다. $0 \sim k \rightarrow \infty$

$$\text{ex) } AR(1) : \text{Under } |\phi_1| < 1, z_t = \phi_1^k z_{t-k} + \sum_{i=0}^{k-1} \phi_1^i \varepsilon_{t-i}$$

② 가역성 만족하는 $MA(q)$ 는 $AR(\infty)$ 로 표현 가능.

$$\text{ex) } MA(1) : \text{Under } |\theta_1| < 1, z_t = a_t - \theta_1 a_{t-1}, a_t = z_t + \theta_1 a_{t-1} = z_t + \theta_1(z_{t-1} + a_{t-2}) = \dots$$

Cf) AR 's PACF, MA 's ACF는 절단의 형태를 보임. $\rightarrow 0$ 이라고 판정하는 기준은?

$$\text{ex) } AR(p) \text{의 경우 } H_0: \phi_{kk} = 0 \quad \text{vs.} \quad H_1: \phi_{kk} \neq 0$$

$$\rightarrow E[\hat{\phi}_{kk}] \cong 0, \text{Var}(\hat{\phi}_{kk}) \cong 1/n \quad \text{for } k \geq p+1$$

$$\rightarrow |\hat{\phi}_{kk}| > z_{\alpha/2} \cdot \frac{1}{\sqrt{n}} \quad (k \geq p+1) \text{ 이면 기각.}$$

$$\Leftrightarrow |\hat{\phi}_{kk}| \leq z_{\alpha/2} \cdot \frac{1}{\sqrt{n}} \text{ 이면 } 100(1-\alpha)\% \text{ 수준에서 } \phi_{kk} = 0 \text{ 이라고 결론.}$$

$$\text{ex) } MA(q) \text{의 경우 } H_0: \theta_k = 0 \quad \text{vs.} \quad H_1: \theta_k \neq 0$$

$$\rightarrow |\hat{\theta}_k| > z_{\alpha/2} \cdot SE(\hat{\theta}_k) \text{ 이면 기각}$$

$$\Leftrightarrow |\hat{\theta}_k| \leq z_{\alpha/2} \cdot SE(\hat{\theta}_k) \text{ 이면 } 100(1-\alpha)\% \text{ 수준에서 } \theta_k = 0 \text{ 이라고 결론지음.}$$

$$\text{이때, } SE(\hat{\theta}_k) \cong \sqrt{\frac{1+2\frac{k}{p}}{n}}$$

4. ARMA 모형

- Bgnd) AR, MA에 너무 많은 모수 포함하면 **모수 추정 효율성 감소** → AR, MA 혼합고려 필요!
- $Z_t = \phi_1 Z_{t-1} + \dots + \phi_p Z_{t-p} + a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q}$
→ $\phi(B)Z_t = \theta(B)a_t$

4.1. ARMA(1,1)

$$- Z_t = \phi_1 Z_{t-1} + a_t - \theta_1 a_{t-1}$$

$$- \text{Prop) } ① E[Z_t] = 0$$

$$② \text{Var}(Z_t) = \frac{(-2\phi_1\theta_1 + 1 + \theta_1^2)}{(1-\phi_1^2)} \sigma_a^2$$

$$③ \gamma_k = \begin{cases} \frac{(-2\phi_1\theta_1 + 1 + \theta_1^2)}{(1-\phi_1^2)} \sigma_a^2 & (k=0) \\ \frac{(\phi_1 - \theta_1)(1 - \phi_1\theta_1)}{1 - \phi_1^2} \sigma_a^2 & (k=1) \\ \phi_1 \gamma_{k-1} & (k \geq 2) \end{cases}$$

$$④ \text{ACF } \rho_k = \begin{cases} 1 & (k=0) \\ \frac{(\phi_1 - \theta_1)(1 - \phi_1\theta_1)}{-2\phi_1\theta_1 + 1 + \theta_1^2} & (k=1) \\ \phi_1 \rho_{k-1} & (k \geq 2) \end{cases} \quad \Rightarrow \text{AR모형처럼 } (q-p+1) \text{ 부터 지수적 감소}$$

$$⑤ \text{PACF} : \text{계수들의 부호와 크기에 의존하며 MA모형처럼 } (p-q+1) \text{ 부터 지수적 감소}$$

- 정상성 / 가역성 조건

정상성 : AR부분 특성방정식 $\phi(B) = 0$ 모든 근의 절대값이 1보다 커야함

→ 정상성 만족하는 ARMA 모형은 MA(∞)로 표현 가능

가역성 : MA부분 특성방정식 $\theta(B) = 0$ 모든 근의 절대값이 1보다 커야함

→ 가역성 만족하는 ARMA 모형은 AR(∞)로 표현 가능

(가정) $\phi(B)=0, \theta(B)=0$ 은 어떤 공통된 근도 공유 X

★
| summary |

	AR(p)	MA(q)	ARMA(p,q)
ACF	지수적 감소	(q+1)시작부터 절단	(q-p+1)시작부터 지수적 감소
PACF	(p+1)시작부터 절단	지수적 감소	(p-q+1)시작부터 지수적 감소
(정상성 & 가역성 조건)			
	AR	MA	ARMA
정상성	조건필요	자체만족	조건필요
가역성	자체만족	조건필요	조건필요

5. 상수항 갖는 ARMA모형

- $$① \text{AR}(p) \text{ 모형 } \begin{cases} a) E[Z_t] = \frac{\mu}{1 - \phi_1 - \phi_2 - \dots - \phi_p} \\ b) \text{Var} : \text{Diff 없는 AR}(p) \text{ 계산과 동일} \\ c) \text{ACF} : \text{Diff 없는 AR}(p) \text{ 계산과 동일} \\ d) \text{PACF} : \text{Diff 없는 AR}(p) \text{ 계산과 동일} \end{cases}$$

② $MA(q)$ 에서 { 평균 $\mu=0$ 인 경우 : $Z_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} \cdots - \theta_q a_{t-q}$
 평균 $\mu \neq 0$ 인 경우 : $Z_t = \theta_0 + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} \cdots - \theta_q a_{t-q}$ ($\theta_0 = \mu$)

③ $ARMA(p, q)$ 에서 { 평균 $\mu=0$: $Z_t = \phi_1 Z_{t-1} + \cdots + \phi_p Z_{t-p} + a_t - \theta_1 a_{t-1} \cdots - \theta_q a_{t-q}$
 평균 $\mu \neq 0$: $Z_t = \theta_0 + \phi_1 Z_{t-1} + \cdots + \phi_p Z_{t-p} + a_t - \theta_1 a_{t-1} - \cdots - \theta_q a_{t-q}$ ($\theta_0 = (1 - \phi_1 - \cdots - \phi_p) \mu$)

V. 비정상 시계열 모형

1. 비정상 시계열의 정상화

5.1.1. 평균의 비정상성

- 추세의 종류 { 결정적 (deterministic) 추세 : 장기간에 걸쳐 나타나는 추세
 확률적 (stochastic) 추세 : 예측할 수 없는 추제로 확률적 성격 지닌 추제로 단위근 시계열이라 함
 $\rightarrow \nabla^d$ 필요

5.1.2. 분산의 비정상성 : Box & Cox (1964) 의 정규화 변환 이용

$\rightarrow \lambda^* = \begin{cases} \frac{\lambda^2 - 1}{\lambda} & (\lambda \neq 0) \\ \log(x) & (\lambda = 0) \end{cases}$ (λ : 변환모수로 원자료에서 추정)
 $\rightarrow$ 변환된 자료는 정규분포 가까운 형태 지니며 **역변환 (power transformation)** 이라 함.

(cf) ① 분산안정화는 양수값 갖는 계열에만 정의. 음수 있으면 적절 상수 더해 변환

② 분산안정화 변환은 필요하다면 차별 등 다른 분석하기 전에 수행

③ 역 변환은 분산안정화뿐만 아니라 가끔 정규근사 달성할 때도 쓰인다.

2. 자기회귀누적이동평균 (ARIMA) 모형

5.2.1. $ARIMA(p, d, q)$ 모형

- Bgncl) $AR(1)$: $Z_t = Z_{t-1} + \varepsilon_t \Leftrightarrow (1-B)Z_t = \varepsilon_t$ (정상시계열) $\sim ARMA$ 일때 이 모형을 $ARIMA$ 라 한다.

$\rightarrow$ 일반화) $(1-B)^d Z_t = X_t$ 가 정상시계열이고

$\phi(B)X_t = \theta(B)\varepsilon_t$ where $\phi(B) = 1 + \phi_1 B + \cdots + \phi_p B^p$, $\theta(B) = 1 + \theta_1 B + \cdots + \theta_q B^q$ 로 표현된다면

$\{X_t\}$ 대한 최종모형식은 $\phi(B)(1-B)^d Z_t = \theta(B)\varepsilon_t$ 이다.

- Def) 시계열 $\{Z_t\}$ 가 있을 때,

$\phi(B)(1-B)^d Z_t = \theta(B)\varepsilon_t$ where $\varepsilon_t \sim WN(0, \sigma^2)$, $\phi(B) = 1 + \phi_1 B + \cdots + \phi_p B^p$, $\theta(B) = 1 + \theta_1 B + \cdots + \theta_q B^q$

를 만족하는 (p, d, q) 가 있다면 $ARIMA(p, d, q)$ 를 따른다고 한다. (차수 $d = 0, 1, 2$)

(cf) ① $p=0$: $\{Z_t\} \sim IMA(d, q)$, $q=0$: $\{Z_t\} \sim ARI(p, d)$

② 왜 Integrated 인지 : $W_t = \nabla Z_t$ 로 두면 $Z_t = W_t + W_{t-1} + \cdots + W_1 + Z_0$: 비정상은 정상의 누적 (integrated)

5.2.2. $ARIMA(1, 1, 1)$

- $(1-B)Z_t = W_t$ 라 하면, $(1-\phi_1 B)W_t = (1-\theta_1 B)a_t \rightarrow W_t - \phi_1 W_{t-1} = a_t - \theta_1 a_{t-1}$

$\rightarrow Z_t - Z_{t-1} = \phi_1 (Z_{t-1} - Z_{t-2}) + a_t - \theta_1 a_{t-1}$ ($a_t \sim WN(0, \sigma^2)$)

- $ARIMA(1, 1, 1)$ 은 W_t 에 대해 $ARMA(1, 1)$ 이 되므로

Z_t 의 ACF, PACF는 W_t 에 대한 $ARMA(1, 1)$ 의 ACF, PACF 특성과 같다.

3. 계절 ARIMA (SARIMA)

- Bgncl) 계절형 시계열 자료 : 일반적 시계열 ($\exists$ ARIMA) 은 추세와 계절성 동시에 존재

→ 계절성에 대한 처리 필요

계절성 : 특정 달/계절의 데이터가 높아지거나 낮아지는 경우

$$\begin{array}{ccccccc} x_1 & x_2 & \dots & x_3 & \Rightarrow & \text{주기 내 종속관계 (within period relationship)} & \text{다 가지고 있다} \\ x_{s+1} & x_{s+2} & \dots & x_{2s} & & & \\ \vdots & \vdots & \vdots & \vdots & & & \\ x_{(m-1)s+1} & x_{(m-1)s+2} & \dots & x_{ms} & \Rightarrow & \text{주기 간 종속관계 (between period relationship)} & \end{array}$$

5.3.1. 계절성분 갖는 시계열 모형

- $x_t = S_t + Z_t$ 라 하자. $\{S_t\}$ 는 주기 s 인 계절성분 ($S_t = S_{t-s}$), $\{Z_t\}$ 는 정상시계열 ($E[Z_t] = 0$, 자기공분산 $\gamma_Z(h)$)

- 이때 S_t 들은 서로 독립이고 $E[S_t] = 0$, $\text{Var}(S_t) = \sigma_s^2 < \infty$ 이며 $\{S_t\}$ 와 $\{Z_t\}$ 도 서로 독립이다.

$$\text{이때 } \gamma_x(h) = E[x_t x_{t+h}] = \begin{cases} \sigma_s^2 + \gamma_Z(h) & h = s, 2s, 3s, \dots \\ \gamma_Z(h) & \text{o.w.} \end{cases} \quad \text{이므로 } \{x_t\} \text{ 는 비정상시계열이다.}$$

→ $\{x_t\}$ 정상화를 위해 차분) 계절차분 $\nabla_s Z_t = Z_t - Z_{t-s} = (1-B^s)Z_t$, $\nabla_s Z_t$ 를 D 번 (차수) 시행 : $\nabla_s^D Z_t = (1-B^s)^D Z_t$

$$\varphi_t = (1-B^s)x_t = x_t - x_{t-s} = (S_t + Z_t) - (S_{t-s} + Z_{t-s}) = Z_t - Z_{t-s} \text{ 은 정상시계열의 차분형태로 정상시계열이다.}$$

→ φ_t 를 $\phi(B)\varphi_t = \theta(B)\varepsilon_t$ where $\varepsilon_t \stackrel{iid}{\sim} (0, \sigma^2)$, $\phi(B) = 1 + \phi_1 B + \dots + \phi_p B^p$, $\theta(B) = 1 + \theta_1 B + \dots + \theta_q B^q$ 와 같은

ARMA 모형에 적합시키면 $\phi(B)\nabla_s^D x_t = \theta(B)\varepsilon_t$ 로 표기되고 이를 계절차분모형이라 정의한다.

5.3.2. 추세 & 계절성 갖는 시계열 모형

- $x_t = T_t + S_t + Z_t$ (T_t, S_t, Z_t 는 서로 독립, $T_t = \beta_0 + \beta_1 t + \dots + \beta_r t^r$, $S_t = S_{t-s}$)

$$\rightarrow \nabla_s x_t = \nabla_s T_t + \nabla_s S_t + \nabla_s Z_t$$

$$\rightarrow (1-B)^{r+1} \nabla_s x_t = (1-B)^{r+1} \nabla_s T_t + (1-B)^{r+1} \nabla_s Z_t \quad (\nabla_s t^r = t^r - (t-s)^r, (r-1)\text{차 다항식})$$

→ 이때 $(1-B)^{r+1} \nabla_s T_t = \text{상수 } \mu$ 이며 $(1-B)^{r+1} \nabla_s Z_t$ 는 정상과정이므로

ARMA 모형을 적합시키면

$$\rightarrow \phi(B) \{(1-B)^{r+1} \nabla_s x_t\} = \theta(B)\varepsilon_t \text{ where } \varepsilon_t \sim WN(0, \sigma^2) \text{ 이 되고}$$

이를 추세가 있는 계절차분 모형이라 정의한다.

중간고사

기말고사

5.3.3. 계절 ARMA 모형 : 주기 간 종속관계 규명

$$\begin{aligned} - \text{AR}(1)_s : Z_t &= \phi_1 Z_{t-s} + \varepsilon_t \text{ where } \varepsilon_t \stackrel{iid}{\sim} (0, \sigma^2), s=1, 2 \quad \text{--- ①} \\ &= \sum_{j=0}^{\infty} \phi_1^j \varepsilon_{t-s-j} \quad \text{if } |\phi_1| < 1 : \text{정상시계열} \end{aligned}$$

$$\rightarrow E[Z_{t+k} \times \text{①}] / \gamma_s : \rho_k = \phi_1^k \rho_{k-s}, \quad k \geq 1$$

$$\rho_{-1} \rightarrow \rho_{12} = \phi_1 \rho_0 = \phi_1^2, \quad \rho_{24} = \phi_1 \rho_{12} = \phi_1^3, \dots$$

$$\Rightarrow \underline{\rho_{ks} = \phi_1^k} \quad (k=1, 2, 3, \dots)$$

$$- \rho_1 = \phi_1, \rho_{-1} = \phi_1 \rho_0 = \phi_1^2, \rho_{11} = \phi_1 \rho_1 = \phi_1^3 \quad (\because \rho_k = \rho_{-k})$$

→ 정상시계열 가정하므로 $|\phi_1| < 1$, 즉 $(\phi_1 \neq 1 \text{ 이고 } \rho_1 = \rho_{-1} = 0, \rho_{11} = \rho_{-11} = 0$

⇒ 비슷한 방식으로 계절차 $s, 2s, 3s, \dots$ 이라면 $\rho_k = 0$

$$- \text{AR}(p)_s : Z_t = \phi_1 Z_{t-s} + \phi_2 Z_{t-2s} + \dots + \phi_p Z_{t-ps} + \varepsilon_t \text{ where } \varepsilon_t \stackrel{iid}{\sim} (0, \sigma^2)$$

Notation 주의 특성방정식 $\phi(B^s) = 1 - \phi_1 B^s - \phi_2 B^{2s} - \dots - \phi_p B^{ps}$ where $\varepsilon_t \perp Z_{t-k} \quad (k=1, 2, \dots)$



정상성 조건 : $\phi(B^s) = 0$ 의 모든 근의 절댓값이 1보다 커야 한다.

- $MA(1)_{s=12}$: $Z_t = a_t - \theta_1 a_{t-12}$ where $a_t \stackrel{iid}{\sim} (0, \sigma^2)$

$\rightarrow \gamma_1 = Cov(Z_t, Z_{t-1}) = E[(a_t - \theta_1 a_{t-12})(a_{t-1} - \theta_1 a_{t-13})] = 0$ 이지만

$\gamma_{12} = Cov(Z_t, Z_{t-12}) = E[(a_t - \theta_1 a_{t-12})(a_{t-12} - \theta_1 a_{t-24})] = -\theta_1 \sigma^2$ 이다.

$\Rightarrow$ 즉, $s=12$ 에서만 0이 아닌 ACF를 가지게 된다.



- $MA(Q)_s$: $Z_t = a_t - \theta_1 a_{t-s} - \theta_2 a_{t-2s} - \dots - \theta_Q a_{t-Qs}$ where $a_t \stackrel{iid}{\sim} (0, \sigma^2)$

$\rightarrow$ 가역성 조건: $\theta(B) = 0$ 의 모든 근의 절댓값이 1보다 크면 됨.

$\Rightarrow \Theta(P)_s + MA(Q)_s$ 결합한 모형 = $SARMA(P, Q)$

Def) 시계열 $\{X_t\}$ 가 $\Phi_p(B)\{1-B^s\}^d X_t = \theta_q(B)\varepsilon_t$ where $\varepsilon_t \stackrel{iid}{\sim} (0, \sigma^2)$

$(\Phi_p(B) = 1 - \Phi_1 B^s - \dots - \Phi_p B^{ps}, \theta_q(B) = 1 - \theta_1 B^s - \dots - \theta_q B^{qs})$ 를 만족할때

$\{X_t\} \sim SARIMA(P, D, Q)_s$ 모형은 따른다.

5.3.4. (승법) 계절 ARIMA 모형

- 앞내용 (comb) 계절 섹터에서만 자기상관 있는 모형 고려. (계절 ARMA)

$\rightarrow$ 1) 계절 + 비계절 ARMA (주기간 + 주기 내 종속관계) 포함 모형 설립

① 주기 내 종속성 : 기존 ARIMA

$\phi_p(B)(1-B)^d Z_t = \theta_q(B)a_t$ where $a_t \sim WN$ ($\because$ 아직 주기 간 종속성 존재 X) ——— ②

$(\phi_p(B) = 1 - \phi_1 B - \dots - \phi_p B^p, \theta_q(B) = 1 - \theta_1 B - \dots - \theta_q B^q)$

② 주기 간 종속성 : SARIMA 이용

$\Phi_p(B^s)(1-B^s)^p a_t = \Theta_q(B^s)\varepsilon_t$ where $\varepsilon_t \sim WN(0, \sigma^2)$ ——— ③

$(\Phi_p(B^s) = 1 - \Phi_1 B^s - \dots - \Phi_p B^{ps}, \Theta_q(B^s) = 1 - \theta_1 B^s - \dots - \theta_q B^{qs})$

$\therefore$ ①+② : $\phi_p(B)\Phi_p(B^s)(1-B)^d(1-B^s)^p Z_t = \theta_q(B)\Theta_q(B^s)\varepsilon_t$ where $\varepsilon_t \stackrel{iid}{\sim} (0, \sigma^2)$

을 Box-Jenkins 가 제안한 **SARIMA** 라고 하며

$\{Z_t\} \sim SARIMA(p, d, q) \times (P, D, Q)_s$

Non-seasonal part Seasonal part


ex) $X_t \sim SARIMA(0, 1, 1) \times (0, 1, 1)_{12}$

$\rightarrow (1-B)(1-B^{12})X_t = (1-\theta B)(1-\theta B^{12})\varepsilon_t$

$\rightarrow X_t = X_{t-1} + X_{t-12} - X_{t-13} + \varepsilon_t - \theta\varepsilon_{t-1} - \theta\varepsilon_{t-13}$


출처 (point) 원자료, ACF/PACF 보고 SARIMA (a,b,c) $\times$ (x,y,z) 를 판단할 줄 알아야 함.

ex 1)




$(0, 0, 0)$
 $\times (1, 0, 0)_{12}$
 $\downarrow$
 $SAR(1)_{12}$

ex 2)




$(0,0,0)$
 $\times$
 $(1,0,0)_4$
 $\sigma\sigma$
 $JAR(1)_4$

ex 3)




$(0,0,0)$
 $\times$
 $(0,0,1)_{12}$
 $\sigma\sigma$
 $MA(1)_{12}$

ex 4)




$(0,0,1)$
 $\times$
 $(0,0,1)_{12}$

ex 5)




$(1,0,0)$
 $\times$
 $(1,0,0)_{12}$

ex 6)




$(2,0,0)$
 $\times$
 $(0,0,1)_{12}$

ex 7)




$(0,0,2)$
 $\times$
 $(1,0,0)_{12}$

ex 8)



$(0,0,1)$
 $\times$
 $(0,1,1)_{12}$

ex 9)



(2, 1, 1)
x
(1, 1, 1)₁₂

4. 단위근 검정 (Unit Root test)

Bgnd) 정상/비정상 구분 하는데 ACF 이용하는 것보다 객관적인 방법 모색

Def) 확률과정이 단위근을 갖는다는 것은 과정의 특성방정식이 1을 근으로 가지는 경우

→ 비정상 *but* 반드시 추세를 갖진 X

→ 특성방정식 다른 근들이 단위원 내부에 있으면 일차차분만으로 정상 과정이 되나, 그렇지 않으면 몇 차례 걸친 차분 필요

→ 이런 특징으로 단위근 과정을 "차분-정상"이라고도 한다

단위근 검정 방법) H_0 : 단위근 (차분정상성) vs. H_1 : NOT H_0 .

1. DF Test : AR(1) 모형 대해 제안

2. ADF Test : ARMA로 확장, 모든 정상시계열은 고차원 AR로 근사될 수 있다고 가정하고 이론 전개

3. DHF Test : 계절 단위근 검정

4. PP Test : DF & ADF 일반화, 비모수 방법

외 Z-A, P (1988), M & K (1999) : 비계열 단위근과 계절단위근 동시 검정

정상성 검정) H_0 : 정상적 과정이다 vs. H_1 : 과정이 단위근을 가진다

1. KPSS test (1992) - 비모수적

2. L & M (1994) - 모수적

5.4.1. DF Test (1979)

- ex) AR(1) : $Z_t = \phi_1 Z_{t-1} + \varepsilon_t$ where $\varepsilon_t \sim WN$

→ $H_0: \phi_1 = 1$ vs. $H_1: \phi_1 < 1$ (one-side left tail test)

→ $\nabla Z_t = (\phi_1 - 1)Z_{t-1} + \varepsilon_t = \gamma Z_{t-1} + \varepsilon_t$

→ $H_0: \gamma = 0$ vs. $H_1: \gamma < 0$

→ $\hat{\tau}_{\phi=1} = \frac{\hat{\phi}}{SE(\hat{\phi})} \cong n(\hat{\phi} - 1)$ (tau(τ) test)
↳ DF Dist.

Cf) 3 ver. $\left\{ \begin{array}{l} 1) \nabla Z_t = \gamma Z_{t-1} + \varepsilon_t : \text{pure } \sigma.w. \\ 2) \nabla Z_t = \alpha + \gamma Z_{t-1} + \varepsilon_t : \text{pure } \sigma.w. \text{ w/ drift} \\ 3) \nabla Z_t = \alpha + \beta t + \gamma Z_{t-1} + \varepsilon_t : \text{pure } \sigma.w. \text{ w/ drift \& linear time trend} \end{array} \right.$

→ 각 모형들은 sample size 미 맞는 각자 critical value를 갖고 있다.

5.4.2. ADF Test (1984)

Bgnd) ① DF test는 ε_t 가 iid한 AR(1) 모형에서만 타당.

② ε_t 가 iid의 가정을 충족하지 못할 경우 (자기상관 및 이분산) 시계열의 차분변수의 시차변수를 설명변수로 포함

③ AR(p) 나 ARMA(p,q)로 확장해 단위근 존재 확인할 필요성

-ex) AR(3) : $Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \phi_3 Z_{t-3} + \varepsilon_t$ where $\varepsilon_t \stackrel{iid}{\sim} WN$

$$\rightarrow Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + (\phi_3 Z_{t-2} - \phi_3 Z_{t-2}) + \phi_3 Z_{t-3} + \varepsilon_t$$

$$= \phi_1 Z_{t-1} + (\phi_2 + \phi_3) Z_{t-2} - \phi_3 \nabla Z_{t-2} + \varepsilon_t$$

$$\rightarrow Z_t = \phi_1 Z_{t-1} + (\phi_2 + \phi_3) Z_{t-2} + (\phi_2 + \phi_3) Z_{t-1} - (\phi_2 + \phi_3) Z_{t-1} - \phi_3 \nabla Z_{t-2} + \varepsilon_t$$

$$= (\phi_1 + \phi_2 + \phi_3) Z_{t-1} - (\phi_2 + \phi_3) \nabla Z_{t-1} - \phi_3 \nabla Z_{t-2} + \varepsilon_t$$

$$\rightarrow \nabla Z_t = -\{1 - (\phi_1 + \phi_2 + \phi_3)\} Z_{t-1} - (\phi_2 + \phi_3) \nabla Z_{t-1} - \phi_3 \nabla Z_{t-2} + \varepsilon_t$$

$$\rightarrow \gamma = -(1 - \sum_{i=1}^p \phi_i), \quad \phi_j^* = -\sum_{j=1}^p \phi_j \quad \text{z 높는다 하면}$$

AR(p) 과정을 따르는 시계열 Z_t 는

$$\nabla Z_t = \gamma Z_{t-1} + \phi_1^* \nabla Z_{t-1} + \dots + \phi_{p-1}^* \nabla Z_{t-p+1} + \varepsilon_t$$

$$= \gamma Z_{t-1} + \sum_{j=1}^{p-1} \phi_j^* \nabla Z_{t-j} + \varepsilon_t$$

이에 따라 이전에 다른 3 ver. 은

$$1) \nabla Z_t = \gamma Z_{t-1} + \sum_{j=1}^{p-1} \phi_j^* \nabla Z_{t-j} + \varepsilon_t$$

$$2) \nabla Z_t = \alpha + \gamma Z_{t-1} + \sum_{j=1}^{p-1} \phi_j^* \nabla Z_{t-j} + \varepsilon_t$$

$$3) \nabla Z_t = \alpha + \beta t + \gamma Z_{t-1} + \sum_{j=1}^{p-1} \phi_j^* \nabla Z_{t-j} + \varepsilon_t$$

$$\rightarrow H_0: \gamma = 0 \quad \text{vs.} \quad H_1: \text{not } H_0 \quad (\text{검정 절차는 DF test와 동일})$$

5.4.3. PP Test (1988)

- 단위근 검정을 보다 포괄적 이론 개발

- ADF test와 가장 큰 차이점 : ε_t 를 WN으로 가정하지 않고 자기상관 및 이분산 현상을 갖는 요차항 이용해 자기상관 처리

- ADF Test처럼 Lag length 지정할 필요 X

- William Schwert (1987)는 Monte-Carlo 연구에 근거해 PP 검정은 H_0 기각하는 경향이 강해 (size distortion) 교차검정 위해 ADF 검정을 이용할 것을 권고

Cf) 단위근 검정 Criticism : ADF/PP 검정은 안기 많지만

유한개의 자료수에서 power/size 문제를 잠재적으로 겪는다고 알려짐

- Main Criticism : Power of tests is low if the process is stationary but w/a root close to non-stationary boundary

ex) 작은 수 자료에서 $\phi=1$ (비정상) / $\phi=.978$ (정상) 구별력이 떨어짐


- One potential sol to these issues : Use a stationary test (like KPSS test) under H_0 .

Cf) H_0 : 정상이다 vs. H_1 : 단위근

($\leftrightarrow$ 앞선 두 검정방법의 가설)

VII 장. 모형의 식별, 추정, 진단 및 예측

1. "



6.1.1. 모형 식별

- 잠정적 (S) ARIMA (p, d, q) × (P, D, Q)_s 모형 찾기
- 모수 절약의 법칙 principle of parsimony
- 1step : ① 시도포 → 정상성 검증 → 1/ 비정상 then 적당 변환 (분산 안정화, (S)diff) 해 정상으로 만들기
- ② 정상성 만족하는 시계열의 ACF, PACF 관찰
- ③ p, q (or P, Q) 식별 : 보통 n ≥ 50, (S)ACF & (S)PACF 개수 ≥ n/4

Recap)	AR(p)	MA(q)	ARMA(p, q)
ACF	지수적 감소	(q+1) 시작부터 절단	(q-p+1) 시작부터 지수적 감소
PACF	(p+1) 시작부터 절단	지수적 감소	(p-q+1) 시작부터 지수적 감소

Cf) 모형 식별용 통계량

$$\begin{cases}
 AIC = -2 \ln(L) + 2k \\
 BIC = -2 \ln(L) + 2 \ln(k) \\
 JBC = -2 \ln(L) + \ln(N)k \\
 HQC = -2 \ln(L) + 2 \ln(\ln(N))k
 \end{cases}
 \quad \text{where } L = L(\theta), N = n, k = p+q+1 \text{ or } p+q$$

⇒ A model w/ smaller value is a better model.

6.1.2. 모수 추정

① Conditional LSE : 회귀분석의 LSE 적용

ex) AR(1)

$$(\hat{\phi}, \hat{\mu}) = \underset{\phi, \mu}{\operatorname{Argmin}} S(\phi, \mu) \quad \text{where } S(\phi, \mu) = \sum_{t=2}^n \{x_t - \mu - \phi(x_{t-1} - \mu)\}^2$$

$$1) \frac{\partial S(\phi, \mu)}{\partial \mu} = 2(1+\phi) \sum_{t=2}^n (x_t - \mu - \phi(x_{t-1} - \mu)) = 0$$

$$\rightarrow \sum_{t=2}^n (x_t - \mu - \phi(x_{t-1} - \mu)) = 0$$

$$\rightarrow \hat{\mu} = \frac{1}{n} \sum_{t=2}^n x_t + \frac{\phi}{(n-1)(1-\phi)} (x_n - x_1) \approx \frac{1}{n} \sum_{t=2}^n x_t \quad \text{if } n \rightarrow \infty$$

$$2) \frac{\partial S(\phi, \mu)}{\partial \phi} = 2 \sum_{t=2}^n (x_t - \mu - \phi(x_{t-1} - \mu))(-x_{t-1} + \mu) = 0$$

$$\rightarrow \sum_{t=2}^n (x_t - \mu)(x_{t-1} - \mu) - \phi \sum_{t=2}^n (x_{t-1} - \mu)^2 = 0$$

$$\rightarrow \hat{\phi} = \frac{\sum_{t=2}^n (x_t - \mu)(x_{t-1} - \mu)}{\sum_{t=2}^n (x_{t-1} - \mu)^2} \xrightarrow{\mu \rightarrow \hat{\mu}} \tilde{\phi} = \frac{\sum_{t=2}^n (x_t - \hat{\mu})(x_{t-1} - \hat{\mu})}{\sum_{t=2}^n (x_{t-1} - \hat{\mu})^2} //$$

$$\text{또한, } \hat{\sigma}^2 = \frac{1}{n-2} \sum_{t=2}^n \{x_t - \hat{\mu} - \tilde{\phi}(x_{t-1} - \hat{\mu})\}^2$$

② 적률추정법 Method of Moment

1/2 Idea) $\frac{1}{n} \sum_{i=1}^n x_i^k \approx E[x^k]$

- AR(1) : $x_t = \phi x_{t-1} + w_t$ or $1) \phi : \gamma(1) = E[x_t x_{t-1}] = \phi E[x_{t-1}^2] + E[w_t x_{t-1}] \rightarrow \phi = \gamma(1) / \gamma(0)$

$\rightarrow V_{w_t}(x_{t-1}) = \gamma(0)$
 $0 (\because E[w_t x_j] = 0)$

$\rightarrow \gamma(0) \because x_t^2 \approx x_{t-1}^2 + w_t^2$ (정확하게) $\rightarrow 0$
 $\rightarrow \sigma^2$

$\sigma^2 : \gamma(0) = E[x_t^2] = \phi^2 E[x_{t-1}^2] + 2\phi E[x_{t-1} w_t] + E[w_t^2] \rightarrow \sigma^2 = (1-\phi^2) \gamma(0)$

$$\begin{aligned}
 \hat{\gamma}(0) &= \hat{V}_{w_t}(x_t) = \frac{1}{n} \sum x_t^2 \\
 \hat{\gamma}(1) &= \hat{C}_{w_t}(x_t, x_{t-1}) = \frac{1}{n} \sum x_t x_{t-1}
 \end{aligned}
 \Rightarrow \hat{\phi} = (1 - \hat{\phi}^2)^{-1} \hat{\gamma}(1) //$$

- AR(2) : $x_t = \phi_1 x_{t-1} + \phi_2 x_{t-2} + w_t$

$$\begin{aligned} p_1 &= \phi_1 + \phi_2 p_1 \\ p_2 &= \phi_1 p_1 + \phi_2 \end{aligned} \quad \xrightarrow{p_1 \rightarrow \hat{p}_1} \quad \hat{\phi}_1 = \frac{\hat{p}_1 - (1 - \hat{p}_1^2)}{1 - \hat{p}_1^2}, \quad \hat{\phi}_2 = \frac{\hat{p}_2 - (1 - \hat{p}_1^2)}{1 - \hat{p}_1^2}$$

- MA(1) : $x_t = w_t - \theta_1 w_{t-1}$

$$p_1 = \frac{-\theta_1}{1 + \theta_1^2} \quad \xrightarrow{p_1 \rightarrow \hat{p}_1} \quad \hat{\theta}_1 = \frac{-1 \pm \sqrt{1 - 4\hat{p}_1^2}}{2\hat{p}_1} \quad (|\hat{\theta}_1| < 1 \rightarrow \hat{\theta}_1 = \frac{-1 + \sqrt{1 - 4\hat{p}_1^2}}{2\hat{p}_1})$$

($|\hat{\theta}_1| > 1/2$ 이면 θ_1 실수근 존재하지 않고 적률추정이 불가능)

Cf) MA(q) 적률추정량은 복잡하고 좋지 않아 거의 사용되지 않음.

- ARMA(1,1) : $x_t = \phi x_{t-1} + w_t - \theta_1 w_{t-1}$

$$\rightarrow p_k = \frac{(\phi_1 - \theta_1)(1 - \phi_1 \theta_1)}{-2\phi_1 \theta_1 + 1 + \theta_1^2} \phi_1^{k-1} \quad (k=1, 2, 3, \dots) \quad \rightarrow \hat{\phi}_1 = \hat{p}_2 / \hat{p}_1$$

$$\rightarrow \hat{\phi}_1, \hat{p}_1 \text{ 통해 } \hat{p}_1 = \frac{(1 - \hat{\phi}_1 \theta_1)(\hat{\phi}_1 - \theta_1)}{-2\phi_1 \theta_1 + 1 + \theta_1^2} \text{ 방정식을 풀면 2개의 근이 나오며 이중 가역성 조건을 만족하는 근이}$$

θ_1 의 적률추정량이 된다.

Cf) ARMA(p,q)는 비효율적이라 MLE의 초기값 정도로만 사용됨.

© MLE

- Def) 무도함수 : $X \sim N(\mu, \sigma^2)$ 인 $(x_1, \dots, x_n)$ 이 있다 하자.

$$\rightarrow f(x_1, \dots, x_n) \stackrel{\text{독립}}{=} f(x_1) \times \dots \times f(x_n) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

$$\rightarrow \mathcal{L}(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

$\rightarrow$ 편의 위해 $l(\mu, \sigma^2) = \log \mathcal{L}(\mu, \sigma^2)$ 을 사용

$\rightarrow$ ARMA의 관측치 ($\vec{Z}$)는 독립이 아니므로 무도함수 구성이 어렵다.

$$\rightarrow \vec{\alpha} \sim \text{WN} \text{ 을 이용해 } \mathcal{L}(\theta; \vec{\alpha}) = (2\pi\sigma_a^2)^{-n/2} \exp\left[-\frac{\sum a_t^2}{2\sigma_a^2}\right]$$

ex) AR(1) : $z_t = \phi_1 z_{t-1} + a_t \rightarrow a_t = z_t - \phi_1 z_{t-1} \dots a_1 = z_1 - \phi_1 z_0$ 초기 조건 1) 적률가정 $\rightarrow$ 2변 무도함수
2) 예측 초기치 사용 $\rightarrow$ 2변 x 무도함수

- 조건있는 무도함수 : $\log \mathcal{L}(\theta | \vec{a}) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma_a^2) - \frac{\sum a_t^2}{2\sigma_a^2}$

ex) ARMA(p,q)에서 $\vec{a}$ 산출

$$a_t = \theta_1 a_{t-1} + \theta_2 a_{t-2} + \dots + \theta_q a_{t-q} + z_t - \phi_1 z_{t-1} - \dots - \phi_p z_{t-p}$$

$$\rightarrow a_1 = \theta_1 a_0 + \theta_2 a_{-1} + \dots + \theta_q a_{1-q} + z_1 - \phi_1 z_0 - \dots - \phi_p z_{1-p}$$

$\rightarrow$ 초기치 필요 $a_* = (a_0, a_{-1}, \dots, a_{1-q}) = \vec{0}$: 보통 0으로 간주

$$z_* = (z_0, z_{-1}, \dots, z_{1-p}) = (\bar{z}, \bar{z}, \dots, \bar{z})$$

$\Rightarrow$ 초기 조건 하 로그 무도함수

$$\log \mathcal{L}(\theta | \vec{a}) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma_a^2) - \frac{S_*(\theta)}{2\sigma_a^2}$$

where $S_*(\theta) = \sum a_t^2(\theta | \vec{a}) \rightarrow$ 최소화 : $\hat{\theta} = \underset{\theta}{\operatorname{argmin}} \frac{S_*(\theta)}{2\sigma^2} \Rightarrow \hat{\sigma}_a^2 = \frac{S_*(\hat{\theta})}{df} \quad (df = n - 2p - q - 1)$

- 조건없는 무도함수 : 과거값 대해 후방예측

$$z_t = \phi_1 z_{t-1} + \dots + \phi_p z_{t-p} + a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q}$$

$$\rightarrow z_t = \phi_1 z_{t+1} + \dots + \phi_p z_{t+p} + b_t - \theta_1 b_{t+1} - \dots - \theta_q b_{t+q}$$

i.e. 미래값(관측치)으로 과거값 예측

ex) AR(1) : $z_t = \phi_1 z_{t-1} + a_t \Leftrightarrow z_t = \phi_1 z_{t+1} + b_t \rightarrow$ 초기값 : $E(a_0) = E(z_0) - \phi_1 E(z_{-1})$

$$E(z_0) = \phi_1 E(z_{-1}) + E(b_0) = \phi_1 z_{-1}$$

$$E(z_{-1}) = \phi_1 E(z_0) + E(b_{-1}) = \phi_1 z_1$$

6.1.3. 모형의 진단 : 잠정 모형이 실제 모형으로서 타당한가?

진단법 1) **과적합 진단법** *Overfitting Diagnosis*

(Idea) 잠정모형보다 차수가 한 단계 더 큰 모형을 고려해 선택된 잠정모형이 이상 있는지 검토

모든 첫 추정 ACF/PACF가 명확한 특징을 안 보일 때 유용함

- Q1) 해당 과정에서 추가되는 모수가 0으로 판단되는가?
Q2) 이전 추정값 $\approx$ 과적합 시킨 후 모수 추정값?

ex) 잠정 모형: $MA(1)$, then

모형	모수	추정값	표준오차추정값	t값
$MA(1)$	θ_1	-0.626	0.025	-25.29
$ARMA(1,1)$	θ_1	-0.586	0.041	-14.27
	ϕ_1	0.064	0.051	1.26
$MA(2)$	θ_1	-0.65	0.032	-20.54
	θ_2	-0.04	0.032	-1.26

- ∴ ① ϕ_1 과 θ_2 는 0이라 판단하고
② 세 모형의 θ_1 값이 비슷하다고 한다면 $\Rightarrow$ 적합결과에 특별한 이상이 없다.

Cf) $H_0: MA(1)$ 이 참모형 ; 이는 간사적으로 평균이 0인 시를 따른다는 사실이 알려져 있으므로 이를 이용해 모수가 0인지를 검정 가능

진단법 2) **잔차 이용 : 잔차 $\{e_t\}$ 는 $\{e_t\}$ 특성을 보이는가?**

- ㉠ 평균이 0 : 잔차 표본평균 7개 표준오차와 비교
㉡ 등분산 + 상수 : 잔차 산점도가 0 기준 고르게 퍼짐
㉢ 서로 독립, 즉 잔차 자기상관이 무시할만큼 작을가: **표본 자기상관함수** 통해 가설검정

$$H_0: \rho_e(k) = 0, k \geq 1 \quad \text{vs.} \quad \text{NOT } H_0$$

($\rightarrow \text{Var}(\rho_e(k)) \approx 1/n$)

$$\rightarrow \alpha\text{에서 기각역: } |\rho_e(k)| \geq z_{\alpha/2} \cdot \text{SE}(\rho_e(k))$$

→ Prob) 각 시차별 표준 자기상관계수를 검정하므로 제1종오류를 지나치게 크게 한다는 단점

: 시차 1이상의 자기상관계수가 0임을 동시검정해야 함에도 통계학적 어려움으로 각 시차 대해 α 의 개별검정을 함.

→ 1ol) 포트만토 Portmanteau 통계량 or Q-통계량

$$- H_0: \rho_e(k) = 0, k \geq 1 \quad \text{vs.} \quad H_1: \text{NOT } H_0$$

$$- Q = n(n+2) \sum_{k=1}^K \frac{\hat{\rho}_e(k)^2}{n-k} \sim \chi^2_{(K-p-q-1)}$$

where K is the max lag being considered

- If $Q \geq 100 \times \alpha\%$, then reject H_0 .

6.1.4. 모형의 예측 : $x_{1:n}$ 관측했을 때 $n+l$ 시점의 값 $\hat{x}_n(l)$ 을 예측값이라 하자

- 평균제곱오차 (MSE)

$$MSE = E[(\hat{x}_{n+l} - x_{n+l})^2 | \vec{x}]$$

따라서, 현 시점까지 자료가 관측됐을 때 MSE를 최소화하는 $\hat{x}_n(l)$ 은 조건부 기대치로 정의

$$\hat{x}_n(l) = E[x_{n+l} | x_n, x_{n-1}, \dots]$$

ex) AR(1): $x_t = \phi x_{t-1} + \varepsilon_t$ 에서 $t=n \rightarrow n+l$ 예측

- 1단계 전방 예측값: $\hat{x}_{n+1} = \hat{x}_n(1) = E[x_{n+1} | x_n, x_{n-1}, \dots, x_1] = E[\phi x_n + \varepsilon_{n+1} | x_n, \dots, x_1]$

$$= \phi E[x_n | x_n, \dots, x_1] + E[\varepsilon_{n+1} | x_n, \dots, x_1]$$

$$= \phi x_n$$

- 2단계 전방 예측값: $\hat{x}_{n+2} = \hat{x}_n(2) = E[x_{n+2} | x_n, \dots, x_1] = \phi E[x_{n+1} | x_n, \dots, x_1] + E[\varepsilon_{n+2} | x_n, \dots, x_1]$

$$= \phi \hat{x}_n(1) = \phi^2 x_n$$

$\Rightarrow$ l단계 전방 예측값: $\hat{x}_{n+l} = \hat{x}_n(l) = E[x_{n+l} | x_n, \dots, x_1] = \phi^l \hat{x}_n(1) = \phi^l x_n$

- 예측오차:

$$e(1) = \hat{x}_{n+1} - x_{n+1} = \phi x_n - x_{n+1} = \phi x_n - (\phi x_n + \varepsilon_{n+1}) = -\varepsilon_{n+1} \sim (0, \sigma^2)$$

$$e(2) = \hat{x}_{n+2} - x_{n+2} = \phi^2 x_n - x_{n+2} = \phi^2 x_n - (\phi x_{n+1} + \varepsilon_{n+2}) = \dots = -(\phi \varepsilon_{n+1} + \varepsilon_{n+2}) \sim (0, (\phi^2 + 1)\sigma^2)$$

$$\Rightarrow e(l) \sim (0, \sigma^2 \frac{1-\phi^{2l}}{1-\phi^2} \xrightarrow{l \rightarrow \infty} \frac{\sigma^2}{1-\phi^2})$$

ex) MA(1): $x_t = \varepsilon_t - \theta_1 \varepsilon_{t-1}$ 에서 $t=n \rightarrow t=n+l$ 예측.

- 1단계 전방 예측: $\hat{x}_{n+1} = x_n(1) = E[x_{n+1} | x_n, \dots, x_1] = E[\varepsilon_{n+1} - \theta_1 \varepsilon_n | x_n, \dots, x_1] = -\theta_1 \varepsilon_n$

- 2단계 전방 예측: $\hat{x}_{n+2} = x_n(2) = E[x_{n+2} | x_n, \dots, x_1] = E[\varepsilon_{n+2} - \theta_1 \varepsilon_{n+1} | x_n, \dots, x_1] = 0$

$\Rightarrow$ l단계 전방 예측: $\hat{x}_{n+l} = x_n(l) = 0 \quad (l \geq 2)$

- 예측오차

$$e(1) = \hat{x}_{n+1} - x_{n+1} = \theta_1 \varepsilon_n - x_{n+1} = \theta_1 \varepsilon_n - (\varepsilon_{n+1} - \theta_1 \varepsilon_n) = -\varepsilon_{n+1} \sim (0, \sigma^2)$$

$$\Rightarrow e(l) = -\varepsilon_{n+l} - \theta_1 \varepsilon_{n+l-1} \quad (l \geq 2) \sim (0, (1+\theta^2)\sigma^2)$$

$$95\% \text{ CI} = \hat{x}_{n+l} \pm 1.96 \sqrt{\text{Var}(e(l))}$$

(f) ARIMA 모형 미래 예측의 특징

1. AR(p) (& AR(p)_s) 특징: $\hat{x}_{n+l} \rightarrow \mu$ as $l \rightarrow \infty$

2. MA(q) (& MA(q)_s): $\hat{x}_{n+l} \rightarrow \mu$ as $l \rightarrow q$. 즉 q 시차까지만 예측 가능 (q+1 시차부터는 예측능력 X)
↓
Q차까지만 예측 가능

3. ARMA(p,q) (& ARMA(p,q)_s): $\hat{x}_{n+l} \rightarrow \mu$ as $l \rightarrow \infty$. 즉 ARMA는 단기예측만 유효. 장기예측은 사용 X

4 이외에도 ARIMA에서 drift 포함 여부, I 차수 등 따라 달라진다.

VII 장. 전이함수 (백색) 잡음 모형

Preview)-ARIMA + 상관성 분석 후 예측에 도움될 정보, 다변량 시계열 분석 중 하나.

- "출력 시계열 = linear combination of 입력 시계열 ($\# \geq 1$)" 의 시계열 회귀분석의 일반화된 개념
- 시계열 방법 + 인과적 방법 (외생변수 영향 고려) 결합한 선형시스템 예측법
- 사용의 주된 목적 : 변수 간 관련성 설명(X)

입출력 시계열 간 동적관련성 분석해 기존 단변량 시계열 개선

- 장점(+): 1. 동적 관계 모델링
- 2. 유연성
- 3. 시차효과 반영
- 4. 다중 입력변수 처리


- 분석 기본 가정 : 1. 입력 시계열끼리 서로 독립
- 2. 입력 / 출력 시계열, 잡음항 : 정상성 만족
- 3. 입력 $\xrightarrow{\text{noise}}$ 출력, 즉 내생성 X
- 4. 입력 계열 & 잡음항은 서로 독립 & ARMA 따름

1. 전이함수 모형

- (alt) 전이함수는 입력력을 연결하는 일종의 필터 (filter) 역할
- 전이함수가 설명하지 못하는 부분은 잡음항 (noise term)

- $\{Y_t\}$: 출력 시계열 (output), 산출변수, 분석 대상의 반응변수 시계열

- $\{X_t\}$: 입력 시계열 (input), 투입(입력) 변수, $\{Y_t\}$ 설명/예측 돕는 설명변수



7.1.2. single input single output 전이함수 모형

- 가정 ① input, output 각각 1개

② 두 시계열 모두 정상성 만족

- 모형) $Y_t - \delta_1 Y_{t-1} - \delta_2 Y_{t-2} - \dots - \delta_r Y_{t-r} = w_0 X_{t-b} - w_1 X_{t-b-1} - \dots - w_s X_{t-b-s} + a_t$ ———— (a)

$$\Leftrightarrow (1 - \delta_1 B - \delta_2 B^2 - \dots - \delta_r B^r) Y_t = (w_0 B^b - w_1 B^{b+1} - \dots - w_s B^{b+s}) X_t + a_t$$

$$\Leftrightarrow Y_t = \frac{w_s(B) B^b}{\delta_r(B)} X_t + n_t \text{ ————— (b)}$$

$$\text{where } w_s(B) = w_0 - w_1 B - w_2 B^2 - \dots - w_s B^s$$

$$\delta_r(B) = 1 - \delta_1 B - \delta_2 B^2 - \dots - \delta_r B^r$$

b 는 지연모수 (delay parameter) : 입력 충격 $\rightarrow$ 출력에 반영되는 시차

정상성 만족 위해 $\delta_r(B) \neq 0$ 의 모든 근은 단위원 밖에 존재하는 것으로 가정

⑥ 는 또한 선형관계가 있으므로

$$\varphi_t = v_0 X_t + v_1 X_{t-1} + \dots + n_t = v(B) X_t + n_t \quad \text{where } v(B) = \sum_{j=0}^{\infty} v_j B^j$$

여기서

- $v(B)$: 전이함수 transfer fn 또는 충격반응함수 impulse response fn
- v_j : 시차 j 에서의 충격반응가중값 impulse response weight 또는 전이함수가중값 transfer fn weight
- 잡음항 $n_t \perp X_t$

Def 7.1.) 전이함수모형의 안정성 조건: $\sum_{j=0}^{\infty} |v_j| < \infty$

$$\Rightarrow \varphi_t = v(B) X_t + n_t \quad (v(B) = \sum_{j=0}^{\infty} v_j B^j, \sum_{j=0}^{\infty} |v_j| < \infty)$$

⑥에서 η_t 는 일반적으로 ωN 가 되지 않으므로

ARMA(p,q) : $\phi(B) \eta_t = \theta(B) \varepsilon_t$ where $\varepsilon_t \sim \omega N$ ε 표현가능

$$\boxed{\therefore \varphi_t = \frac{\omega_s(B) B^b}{\delta_r(B)} X_t + \frac{\theta(B)}{\phi(B)} \varepsilon_t} \quad \text{전이함수 (백색 잡음) 모형}$$

7.1.3. 충격반응가중값과 b, r, σ 관계

If $\omega_s(B), \delta_r(B), b$ are given,

$$\text{then } v(B) = \frac{\omega_s(B) B^b}{\delta_r(B)} \iff \delta_r(B) v(B) = \omega_s(B) B^b$$

$$\iff (1 - \delta_1 B - \delta_2 B^2 - \dots - \delta_r B^r) (v_0 + v_1 B + v_2 B^2 + \dots) = (\omega_0 - \omega_1 B - \omega_2 B^2 - \dots - \omega_s B^s) B^b$$

해당식에 항등식 원리를 적용하면

$$v_j = \begin{cases} 0 & j < b \\ \delta_1 v_{j-1} + \dots + \delta_r v_{j-r} + \omega_0 & j = b \\ \delta_1 v_{j-1} + \dots + \delta_r v_{j-r} - \omega_{j-b} & j = b+1, \dots, b+s \\ \delta_1 v_{j-1} + \dots + \delta_r v_{j-r} & j > b+s \end{cases}$$

Ex 1) $b=0, \sigma=0, r=2$

$$v(B) = \frac{\omega_s(B)}{\delta_r(B)} B^b = \frac{\omega_0 - \omega_1 B - \dots - \omega_s B^s}{1 - \delta_1 B - \dots - \delta_r B^r} B^b = \frac{\omega_0 - \omega_1 B - \omega_2 B^2}{1} \times 1$$

$$\rightarrow \varphi_t = v(B) X_t = \omega_0 X_t - \omega_1 X_{t-1} - \omega_2 X_{t-2}$$

$$\rightarrow v_0 = \omega_0, v_1 = -\omega_1, v_2 = -\omega_2, v_{k \geq 3} = 0$$

Ex 2) $b=3, \sigma=2, r=1$

$$(1 - \delta_1 B - \delta_2 B^2 - \dots - \delta_r B^r) (v_0 + v_1 B + \dots) = (\omega_0 - \omega_1 B - \dots - \omega_s B^s) B^b$$

$$\rightarrow v_j = \begin{cases} 0 & j < b=3 \\ \omega_0 & j = b=3 \\ -\omega_1 + \delta_1 \omega_0 & j = b+1, \dots, b+s=4 \\ \delta_1 v_{j-1} + \delta_2 v_{j-2} & j > 4 \end{cases}$$

7.1.4. 교차상관함수 (Cross-Correlation Ftn)

- 단변량 ACF의 다변량 ver.
- 2개 (Y_t, X_t) 또는 그이상 시계열 관계를 파악하는데 유용
- 두 시계열 관계에서 $\{Y_t\}$ 가 $\{X_t\}$ 과 어떤 시차와 관계될 수 있다 (목적) 당연히 전이함수 모형 설계에 활용
- $\{Y_t\}$ 예측에 유용한 $\{X_t\}$ 시차 찾는 데 유용 : $b, 1, 0$ $\rightarrow$ CCF는 $\{X_t, Y_t\}$ 사이 시차 k 만큼 떨어진 값들 간 선형 상관관계 측정의 함수다 (X)
- CCF : $\text{corr}(X_{t+k}, Y_t)$ 의 집합으로 정의
 - $\forall k < 0, X \text{ leads } Y$ (X가 Y를 선행한다) $\star$ 분석의 짐
 - $\forall k > 0, X \text{ lags } Y$ (X가 Y를 후행한다)

7.1.4. Cross-Correlation Ftn, CCF

- (note) 두 시계열 간 상관관계의 정도와 방향을 측정하는 용도로 ACF 확장해 CCF 이용
- $\forall \{Y_t\}, \{X_t\}$ 가 정상성을 만족하면

Def 7.2) $\gamma_{xy}(k) = E[(X_t - \mu_x)(Y_{t+k} - \mu_y)] \quad k = 0, \pm 1, \pm 2, \dots \approx \text{자기공분산}$

(단, $\mu_x = E[X], \mu_y = E[Y]$ 보충 4t)

$$\rho_{xy} = \text{Corr}(X_t, Y_{t+k}) = \frac{\gamma_{xy}(k)}{\sigma_x \sigma_y} = \frac{\gamma_{xy}(k)}{\sqrt{\gamma_x(0) \gamma_y(0)}}$$

$\star$ 성질) ACF와 달리 대칭 성립 X

$$\gamma_{xy}(k) \neq \gamma_{yx}(-k) \quad \leftrightarrow \quad \rho_{xy}(k) = \rho_{yx}(-k) \quad k = 0, \pm 1, \pm 2, \dots$$

ex) AR(1)에서 a_t, Z_t 간 CCF는?

$$(1 - \phi B) Z_t = a_t$$

$$\rightarrow Z_{t+k} = \frac{1}{1 - \phi B} a_{t+k} = a_{t+k} + \phi a_{t+k-1} + \phi^2 a_{t+k-2} + \dots$$

$$\rightarrow \gamma_{az}(k) = E[a_t Z_{t+k}] = \phi^k \sigma_a^2 \quad (k \geq 0)$$

$$\gamma_{az}(k) = 0 \quad (k < 0)$$

$$\rightarrow \text{CCF는 } \sigma_a^2 = \frac{\sigma^2}{1 - \phi^2} \text{ 이므로 } \rho_{az} = \begin{cases} \phi^k \sqrt{1 - \phi^2} & (k \geq 0) \\ 0 & (k < 0) \end{cases}$$

(f) 단변량 ARMA : $\phi_p(B) Z_t = \theta_q(B) a_t \Leftrightarrow Z_t = \frac{\theta_q(B)}{\phi_p(B)} a_t$: 잡음항 없는 전이함수의 특수 case

7.1.5. CCF와 전이함수 모형 간 관계

$$Y_{t+k} = v_0 X_{t+k} + v_1 X_{t+k-1} + v_2 X_{t+k-2} + \dots$$

$$\rightarrow \gamma_{xy}(k) = E[Y_{t+k} X_t] = v_0 E[X_t X_{t+k}] + v_1 E[X_{t+k-1} X_t] + \dots$$

$$= v_0 \gamma_{xx}(k) + v_1 \gamma_{xx}(k-1) + \dots$$

$$\rightarrow \rho_{xy}(k) = \frac{\gamma_{xy}(k)}{\sigma_x \sigma_y} = \frac{\sigma_x \{ v_0 \gamma_{xx}(k) + v_1 \gamma_{xx}(k-1) + \dots \}}{\sigma_x \sigma_x \sigma_y}$$

$$= \frac{\sigma_x}{\sigma_y} \times \{ v_0 \rho_{xx}(k) + v_1 \rho_{xx}(k-1) + \dots \}$$

해석 : CCF $\rho_{xy}(k)$ 와 충격반응가중값 v_k 의 관계는 $\{X_t\}$ 의 자기상관구조에 따라 결정된다.

$$\rightarrow \forall \{X_t\} \text{가 } \text{WSS} \text{ 이면 } (\rho_{xx}(0)=1, \rho_{xx}(k \neq 0)=0) \quad v_k = \frac{\sigma_y}{\sigma_x} \rho_{xy}(k) \propto \rho_{xy}(k) \Rightarrow v_k \text{ 크기 / 의미성 판단 가능}$$

$$\rightarrow \text{또 표준 CCF } r_{xy}(k) \text{ 통해 } \hat{v}_k = \frac{S_y}{S_x} r_{xy}(k) \text{ 추정 가능하다.}$$

2. 사전백색화 과정

사전백색화
과정

① 입력 시계열의 사전백색화

- 먼저 $\{x_t\}$ 대해 ARMA 설정해 WN 잔차계열 $\{\alpha_t\}$ 만듦.

$$\text{i.e., } \phi_x(B) x_t = \theta_x(B) \alpha_t$$

$$\Leftrightarrow \alpha_t = \underbrace{\theta_x^{-1}(B) \phi_x(B)}_{\text{사전백색화 모수}} x_t \sim WN(0, \sigma_\alpha^2)$$

② 출력 시계열 변환

$$\hat{\beta}_t = \theta_x^{-1}(B) \phi_x(B) y_t \quad (\text{만드시 } \sim WN \text{ 일 필요 } \times, \text{ 일반적으로 자기공통된 계열})$$

③ $\{\hat{\alpha}_t\}$ 와 $\{\hat{\beta}_t\}$ 간 표본 CCF $\gamma_{\alpha\beta}(k)$ 계산 후 v_k 추정: $\hat{v}_k = \frac{S_\beta}{S_\alpha} \gamma_{\alpha\beta}(k)$

3. 전이함수 모형 식별

- 사전 백색화 과정을 하면 충격반응가중값 = $\{x_t\}, \{y_t\}$ 간 CCF $\times c$ (상수)

→ " 적용하면 충격반응가중값 대신 CCF 분석해도 된다.

7.3.1. Box-Jenkins 방법

- 가장 널리 사용됨

- 사전백색화 거친 시계열자료들의 CCF 형태를 이론적 충격반응함수와 비교해 전이함수모형 식별


$$y_t = \underbrace{\nu(B)}_{\text{표본}} x_t = \frac{\omega_s(B)}{\delta_r(B)} B^b x_t = \frac{\omega_0 - \omega_1 B - \dots - \omega_s B^s}{1 - \delta_1 B - \dots - \delta_r B^r} B^b x_t$$

- 여기서 b : 처음으로 0이 아닌 값이 나온 시차

γ : b 이후 유의한 상관성이 몇 개까지 지속

σ : $\begin{cases} 0 & (b+1) \text{ 이후 유의한 값 } \times \\ 1 & (b+1) \text{ 이후 지수적 감소} \\ 2 & (b+1) \text{ 이후 line } (\sigma \text{ 지수}) \text{ 형태 감소} \end{cases}$

모형 식별에 중요.



(ex)

(b, r, s)	전이함수모형	충격반응가중합수
(2, 0, 0)	$y_t = \omega_0 x_{t-2}$	
(2, 0, 1)	$y_t = (\omega_0 - \omega_1 B) x_{t-2}$	
(2, 0, 2)	$y_t = (\omega_0 - \omega_1 B - \omega_2 B^2) x_{t-2}$	

(b, r, s)	전이함수모형	충격반응가중합수
(2, 2, 0)	$y_t = \frac{\omega_0}{(1 - \delta_1 B - \delta_2 B^2)} x_{t-2}$	
(2, 2, 1)	$y_t = \frac{(\omega_0 - \omega_1 B)}{(1 - \delta_1 B - \delta_2 B^2)} x_{t-2}$	
(2, 2, 2)	$y_t = \frac{(\omega_0 - \omega_1 B - \omega_2 B^2)}{(1 - \delta_1 B - \delta_2 B^2)} x_{t-2}$	

(b, r, s)	전이함수모형	충격반응가중합수
(2, 1, 0)	$y_t = \frac{\omega_0}{(1 - \delta_1 B)} x_{t-2}$	
(2, 1, 1)	$y_t = \frac{(\omega_0 - \omega_1 B)}{(1 - \delta_1 B)} x_{t-2}$	
(2, 1, 2)	$y_t = \frac{(\omega_0 - \omega_1 B - \omega_2 B^2)}{(1 - \delta_1 B)} x_{t-2}$	

7.3.2. 잡음시계열데이터 분석

- 전이함수모형 결정 후 $\{n_t\}$ 모형 설정
- Step 1 : 잡음계열 추정

$$\hat{n}_t = \varphi_t - \omega(B)X_t = \varphi_t - \frac{\hat{\omega}(B)}{\hat{\phi}(B)} X_{t-b}$$

Step 2 : 잡음계열 판별

$\{\hat{n}_t\}$ 의 ACF/PACF 통해 ARMA(p,q) 결정

$$\phi(B)\hat{n}_t = \theta(B)\varepsilon_t, \text{ 즉 } \hat{n}_t = \frac{\theta(B)}{\phi(B)}\varepsilon_t \text{ where } \varepsilon_t \sim WN$$

7.3.3. 전이함수모형 식별 시 유의점들

최종 모형 : $\varphi_t = \frac{\omega_s(B)}{\delta_v(B)} B^b X_t + \frac{\theta(B)}{\phi(B)} \varepsilon_t$

1. $\{X_t\}, \{\varphi_t\}, \{N_t\}$ 모두 정상적 가정 : 차분/분산안정화로 적절 변환
2. 전이함수 식별 과정에서 $\{X_t\}$ 사전백색화 : $\{X_t\} \sim WN$ 이면 필요 X
3. 잡음시계열 $\{N_t\}$ $\perp \{X_t\}$
4. ³ feedback : $\{X_t\} \rightleftharpoons \{\varphi_t\}$, then CCF 구하기 전에 두 시계열 모두 사전백색화해야 함.

4. 전이함수 모형 추정 : 충격반응기증값 추정

$$\varphi_t = \frac{\omega_s(B)}{\delta_v(B)} B^b X_t + \frac{\theta(B)}{\phi(B)} \varepsilon_t$$

$$\rightarrow \phi(B)\delta_v(B)\varphi_t = \phi(B)\omega_s(B)B^b X_t + \delta_v(B)\theta(B)\varepsilon_t$$

$$\rightarrow C(B)\varphi_t = D(B)B^b X_t + E(B)\varepsilon_t$$

$$\text{where } C(B) = (1 - \phi_1 B - \dots - \phi_r B^r)(1 - \delta_1 B - \dots - \delta_v B^v)$$

$$= 1 - C_1 B - C_2 B^2 - \dots - C_{p+r} B^{p+r}$$

$$D(B) = (1 - \phi_1 B - \dots - \phi_r B^r)(\omega_0 - \omega_1 B - \dots - \omega_s B^s)$$

$$= D_0 - D_1 B - \dots - D_s B^{p+s}$$

$$E(B) = (1 - \delta_1 B - \dots - \delta_v B^v)(1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q)$$

$$= 1 - E_1 B - E_2 B^2 - \dots - E_{q+r} B^{q+r}$$

$$\rightarrow \varepsilon_t = \varphi_t - C_1 \varphi_{t-1} - \dots - C_{p+r} \varphi_{t-p-r} - D_0 X_{t-b} + D_1 X_{t-b-1} + \dots + D_{p+s} X_{t-p-s} + E_1 \varepsilon_{t-1} + \dots + E_{q+r} \varepsilon_{t-q-r}$$

여기서 $\{C_i\}, \{D_j\}, \{E_k\}$ 는 $\{\delta_i\}, \{\omega_j\}, \{\phi_k\}, \{\theta_k\}$ 의 함수다.

$$\delta = (\delta_1 \dots \delta_v)^t, \omega = (\omega_0 \dots \omega_s)^t, \phi = (\phi_1 \dots \phi_r)^t, \theta = (\theta_1 \dots \theta_q)^t$$

$\rightarrow$ $\varepsilon_t \sim WN \sim N \text{ dist}$ & 초기값 주어지면,

$$\text{조건부 : } \mathcal{L}(\delta, \omega, \phi, \theta, \sigma_\varepsilon^2 \mid X, \varphi, X_0, \varphi_0, \varepsilon_0) = (2\pi\sigma_\varepsilon^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma_\varepsilon^2} \sum_{t=1}^n \varepsilon_t^2 \right\}$$

무도함수

적절히 선택된 초기벡터

$\rightarrow$ 모수 추정 위해 초기값 대신 그 기대값인 0 으로 놓고 최소화하면

$$\text{조건부 1/E : } S(\delta, \omega, \phi, \theta \mid X_0, \varphi_0, \varepsilon_0 = 0) = \sum_{t=1}^n \varepsilon_t^2 \quad (t_0 = \max(p+q+1, b+p+q+1))$$

→ $\{ \varepsilon_t \} \sim WN \quad \omega / N \text{ dist.}$

미조건부 : $L(d, \omega, \phi, \theta, \sigma_\varepsilon^2 | X, Y) = (2\pi\sigma_\varepsilon^2)^{-n/2} \underbrace{J(d, \omega, \phi, \theta)}_{\text{Jacobian}} \exp\left\{-\frac{1}{2\sigma_\varepsilon^2} \sum_{t=-\infty}^n \varepsilon_t^2\right\}$
 무도함수

→ 최우추정량 = argmax

→ $\forall n \rightarrow \infty$, then $J(d, \omega, \phi, \theta)$ 이 1에 크게 영향을 못 미치며

$$S_*(d, \omega, \phi, \theta) = \sum_{t=-\infty}^n \varepsilon_t^2$$

을 최소화하는 추정량을 미조건부 최소제곱추정량이라 한다.

5. 전이함수 모형 진단

진단 내용 { ① $\{X_t\} \perp \{\varepsilon_t\}$
 ② $\{\varepsilon_t\} \sim WN$

① 1) 교차상관관계 진단 : $\{X_t\}$ 와 $\{\varepsilon_t\}$ 의 CCF의 절대값들 < 표준오차 $\times 2$, $\forall t$

2) 포트만토 *postmontau test* 통계량 사용 H_0 : 독립 vs. H_1 : 독립 X

$$Q_o = m(m+2) \sum_{j=1}^K \frac{1}{m-j} \hat{\rho}_{X\varepsilon}^2(j) \sim \chi^2(K+1-M)$$

where $m = n - t_o + 1$ (잔차개수), $M = \text{모수 } \{\delta, \phi, \omega\} \text{ 개수}$

② $\{\varepsilon_t\} \sim WN$ 진단

- 자기상관관계 진단

- $\{\hat{\varepsilon}_t\}$ 의 ACF는 식자 1 이후 절단돼야 한다

- 포트만토 통계량

$$Q_o = m(m+2) \sum_{j=1}^K \frac{1}{m-j} \hat{\rho}_{\hat{\varepsilon}\hat{\varepsilon}}(j) \sim \chi^2(K-p-q) \quad (m = n - t_o + 1)$$

∴ 진단 결과 { 독립 WN
 0 0

0 X → $\{\varepsilon_t\}$ 의 ARMA 재식별

X X → 전이함수 재식별 / 추정 후 $\{\varepsilon_t\}$ 모형 수정

6. 전이함수모형 예측

유한 차수 다항식

$\epsilon_t \sim WN(0, \sigma_{\epsilon}^2)$

- $MA(1)$ 에 의한 예측은 $\hat{Y}_t = u(B) X_t + n_t = \frac{\omega(B)}{\delta(B)} B^k X_t + \frac{\theta(B)}{\delta(B)} \epsilon_t$ & $\phi(B) X_t = \theta(B) a_t$

$$\rightarrow u(B) = \frac{\omega(B) B^k \theta(B)}{\delta(B) \phi(B)} = u_0 + u_1 B + u_2 B^2 + \dots = 0 \text{ 의 모든 근들은 단위원 밖에 존재}$$

$$\psi(B) = \frac{\theta(B)}{\phi(B)} = 1 + \psi_1 B + \psi_2 B^2 + \dots$$

$$\rightarrow \hat{Y}_t = u(B) \alpha_t + \psi(B) \epsilon_t = \sum_{j=0}^{\infty} u_j \alpha_{t-j} + \sum_{j=0}^{\infty} \psi_j \epsilon_{t-j} \quad (\psi_0 = 1)$$

$$\rightarrow (n+l) \text{ 시점 예측} : \hat{Y}_{n+l} = \sum_{j=0}^{\infty} u_j \alpha_{n+l-j} + \sum_{j=0}^{\infty} \psi_j \epsilon_{n+l-j}$$

$$\rightarrow \text{현재점 } n, l \text{ 시점 후 예측} : \hat{Y}_n(l) = \bar{C}_0^{(1)} \hat{Y}_n + \bar{C}_1^{(1)} \hat{Y}_{n-1} + \dots + \bar{C}_n^{(2)} \alpha_n + \bar{C}_{n+1}^{(2)} \alpha_{n-1} + \dots$$

$$\Leftrightarrow \hat{Y}_n(l) = \bar{E}_0^{(1)} \epsilon_n + \bar{E}_1^{(1)} \epsilon_{n-1} + \dots + \bar{E}_n^{(2)} \alpha_n + \bar{E}_{n+1}^{(2)} \alpha_{n-1} + \dots$$

$$\text{where } \bar{C}_n, \bar{E}_n = \underset{\text{평균제곱오차}}{\text{argmin}} E[\hat{Y}_{n+l} - \hat{Y}_n(l)]^2$$

$$\rightarrow \text{최적화 돌리면 } \bar{E}_k^{(1)} = \psi_{l+k}, \bar{E}_k^{(2)} = u_{l+k} \quad (k=0, 1, 2, \dots)$$

$$\rightarrow \text{대입하면 } \hat{Y}_n(l) = u_l \alpha_n + u_{l+1} \alpha_{n-1} + \dots + \psi_l \epsilon_n + \psi_{l+1} \epsilon_{n-1} + \dots$$

$$\text{이때 예측오차는 } e_n(l) = \hat{Y}_{n+l} - \hat{Y}_n(l)$$

$$= u_0 \alpha_{n+l} + u_1 \alpha_{n+l-1} + \dots + u_{l-1} \alpha_{n+1} + \alpha_{n+l} + \psi_l \epsilon_{n+l-1} + \dots + \psi_{l-1} \epsilon_{n+1}$$

$$\& V_{\text{av}}(e_n(l)) = \sum_{j=0}^{l-1} (u_j^2 \sigma_{\alpha}^2 + \psi_j^2 \sigma_{\epsilon}^2)$$

VIII 장. 이분산성 시계열 모형

0. Intro

- 지금까지 내용) 주로 $Z_t = \phi Z_{t-1} + \epsilon_t$ where $\epsilon_t \stackrel{iid}{\sim} WN(0, \sigma^2)$ 를 다룸

$\rightarrow$ since $\epsilon_i \perp \epsilon_j$, $g(\epsilon_i) \perp g(\epsilon_j)$ & $\epsilon_i^2 \perp \epsilon_j^2$ BUT 현실에선...

- 변동성 군집화 Volatility Clustering : 현대 금융 (after Boettcher Woods system) 에서 중요

- 변동성은 미래 분산이 현재 상황에 의존하면서 결정할 때 나타나는 현상

$$: Z_t = 0.2 Z_{t-1} + \epsilon_t \text{ where } \epsilon_t | \epsilon_{t-1} \sim N(0, 1 + 0.5 \epsilon_{t-1}^2) \Rightarrow \text{변동성이 몰려있게 됨}$$

$\rightarrow$ 조건부 분산을 연구!

$\Rightarrow$ 분산을 시간의 (비선형) 함수 형태로 표현하고 예측하는 이분산 모형이 개발되고 활용됨

1. ARCH 모형 Autoregressive Conditional Heteroskedastic

이분산 t_1 & 이분산 t_2

조건부적

이분산

$$\text{Idea) } Z_t = \phi Z_{t-1} + \epsilon_t \text{ where } \epsilon_t \sim N(0, \sigma^2) \text{ where } \sigma^2 = f(\epsilon_{t-1}^2)$$

8.1.1. ARCH 모형

- 수익률 ($r_t = \frac{P_t - P_{t-1}}{P_{t-1}}$) 의 조건부 분산을 $\sigma_{t|t-1}^2$ 이라 하자.

$\rightarrow r_t^2$ 은 $\sigma_{t|t-1}^2$ 의 불편추정량을 제공하고 상대적 변동성이 큰 구간을 미리 알려준다.

$\rightarrow \text{ARCH}(1) : \sigma_{t|t-1}^2$ 이 반응변수이고 r_t^2 이 공변량

$$r_t = \sigma_{t|t-1} e_t \quad (e_t \stackrel{iid}{\sim} N(0, 1), e_i \perp r_{t-j}) \quad \text{--- (a)}$$

$$\sigma_{t|t-1}^2 = \alpha_0 + \alpha_1 r_{t-1}^2 \quad (\alpha_0 > 0, 0 < \alpha_1 < 1) \quad \text{--- (b)}$$

$$\text{이때, } \text{Var}(r_t | r_{t-j}, j=1,2,3,\dots) = E[\sigma_{t|t-1}^2 e_t^2 | r_{t-j}, j=1,2,3,\dots] = \sigma_{t|t-1}^2 E[e_t^2 | r_{t-j}, j=1,2,3,\dots] \\ = \sigma_{t|t-1}^2 E[e_t^2] = \sigma_{t|t-1}^2 \text{Var}(e_t) = \sigma_{t|t-1}^2$$

$$\textcircled{a}-\textcircled{b} \text{ 을 정리하면 } r_t^2 = \underbrace{\alpha_0 + \alpha_1 r_{t-1}^2}_{\text{AR}(1)} + \underbrace{(\varepsilon_t^2 - 1)}_{\text{오차항 부분}} \sigma_t^2$$

즉, $\{r_t\} \sim \text{ARCH}(1)$ 은 $\{r_t^2\} \sim \text{AR}(1)$ 을 만족시키는 non-Gaussian noise ($\sim \chi^2$) 를 따름.

→ If $\{r_t\} \sim \text{ARCH}(1)$, then $\{r_t^2\} \sim \text{AR}(1)$ (역관계도 성립)

8.1.2. ARCH 모형의 성질

$$\textcircled{1} \quad r_t = \sigma_t \varepsilon_t \quad \text{where} \quad \varepsilon_t \stackrel{iid}{\sim} \mathcal{N}(0,1)$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 r_{t-1}^2 \quad (\alpha_0 > 0) \quad \text{에 대해}$$

$$1) \text{ 조건부 평균 } E[r_t | r_{t-j}] = E[\sigma_t \varepsilon_t | r_{t-j}] = \sigma_t E[\varepsilon_t | r_{t-j}] = \sigma_t \times 0 = 0 \quad \forall t$$

$$\text{비조건부 평균 } E[E[r_t | r_{t-j}]] = E[0] = 0$$

$$2) \text{ 조건부 분산 } \text{Var}(r_t | r_{t-j}) = E[r_t^2 | r_{t-j}] = \sigma_t^2 E[\varepsilon_t^2 | r_{t-j}] = \sigma_t^2 \times 1 = \sigma_t^2 = \alpha_0 + \alpha_1 r_{t-1}^2$$

$$\text{비조건부 분산 } \text{Var}(r_t) = E[r_t^2] = E[E[r_t^2 | r_{t-j}]] = E[\alpha_0 + \alpha_1 r_{t-1}^2] = \alpha_0 + \alpha_1 E[r_{t-1}^2] = \frac{\alpha_0}{1-\alpha_1}$$

$$3) \quad 0 \leq \alpha_1 < 1 \quad (\because \text{Var}(r_t) > 0)$$

$$4) \gamma_{r_t}(h) = \text{Cov}(r_t, r_{t+h}) = E[r_t r_{t+h}] = \sigma_t \sigma_{t+h} E[\varepsilon_t \varepsilon_{t+h}] = 0 \quad \forall h > 0$$

$$5) m_4 = E[r_t^4] = \frac{3\alpha_0^2(1+\alpha_1)}{(1-\alpha_1)(1-3\alpha_1^2)} > 0$$

$$6) \quad 0 \leq \alpha_1^2 < 1/3 \quad (\Leftrightarrow 0 \leq \alpha_1 < 1/\sqrt{3})$$

$$7) \text{ 첨도 } K = E[r_t^4] / (\text{Var}(r_t))^2 = 3 \cdot \frac{1-\alpha_1^2}{1-3\alpha_1^2} > 3 \quad (\mathcal{N} \text{ dist. 의 첨도})$$

$$8) \text{ ARCH}(1) \text{ 의 정상성 조건 : } \alpha_1 < 1$$

$$\textcircled{2} \quad \{r_t\} \sim \text{ARCH}(1) \longrightarrow \{r_t^2\} \sim \text{AR}(1)$$

$$\text{또한 } \{r_t^2\} \text{ 의 } \begin{cases} \text{ACF : } \rho_{r_t^2}(h) = \alpha_1^h \quad (h=0,1,2,\dots) \\ \text{PACF : } \phi_{11} = \alpha_1, \phi_{hh} = 0 \quad (h \geq 2) \end{cases}$$

$$\Rightarrow \text{Def 8.1) } r_t = \sigma_t \varepsilon_t, \quad \varepsilon_t \stackrel{iid}{\sim} \mathcal{N}(0,1)$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 r_{t-1}^2 + \alpha_2 r_{t-2}^2 + \dots + \alpha_p r_{t-p}^2 \quad (\alpha_0 > 0, \alpha_i \geq 0, 1 \leq i \leq p, \forall i > 0)$$

$$\text{을 만족하면 } \{r_t\} \sim \text{ARCH}(p) \text{ 이고}$$

$$\rightarrow \text{Var}(r_t) = \frac{\alpha_0}{1-\sum_{i=1}^p \alpha_i}$$

$$\rightarrow \{r_t\} \sim \text{ARCH}(p), \mathcal{N}\text{-G noise}, \{r_t^2\} \sim \text{AR}(p)$$

$$\rightarrow \text{ARCH}(p) \text{ 정상성 조건 : } \sum_{i=1}^p \alpha_i < 1$$

(f) 실제 경제시계열은
$$\begin{cases} Z_t = \theta Z_{t-1} + \varepsilon_t \\ \varepsilon_t = \sigma_t \varepsilon_{t-1} \quad \text{iid } N(0,1) \\ \sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2 \end{cases} \quad \text{인 threshold ARCH(1)-GARCH(1,1)을 잘 따른다.}$$

8.1.3. ARCH 모형 추정 절차 : 설정 - 추정 - 진단 - 예측

① 모형 설정

1. 회귀추세 / 종속성 제거 : 기존 회귀모형 or B-J의 ARIMA 모형 적합 통해 제거

2. 이분산성 확인 : 1.의 잔차계열의 분산의 종속성 확인

즉 ARCH 효과의 존재성 확인 : 포트만도 검정, LM test, B-J stat ...

3. ARCH 차수결정 : 2 효과가 확인되면 (잔차²)계열 대한 ARCH 차수결정


(f) ① LM test : a) 모형 추정으로 잔차 u_t 획득

$$b) u_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \dots + \alpha_p u_{t-p}^2 + \varepsilon_t \text{의 } R^2 \text{ 산출}$$

$$c) LM = nR^2$$

$$d) LM > \chi^2(p, \alpha) \text{ 이면 reject } H_0. \quad (H_0: \alpha_1 = \alpha_2 = \dots = 0 \text{ (등분산성)})$$

② McLeod-Ljung test는 R에서 제공



③ 모형 모수 추정 : 주로 MLE 사용

$$u_t | u_{t-1}, u_{t-2} \sim N(0, \sigma_t^2)$$

$$\rightarrow \ln L(\theta | Z_{1:n}) = -\frac{1}{2} \sum_{t=1}^n \left[\log(2\pi) + \log(\sigma_t^2) + \frac{u_t^2}{\sigma_t^2} \right] \quad (u_t = Z_t - \beta X_t)$$

$$\text{where } \sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \dots + \alpha_p u_{t-p}^2$$

④ 모형 진단 : $r_t = \sigma_t \varepsilon_t$, 많은 test 이용

- Jarque-Bera test

$$H_0: \text{잔차 } (e_{1:n}) \sim N \quad \text{vs.} \quad H_1: \text{NOT } H_0$$

$$\text{stat. } JB = n \left\{ \frac{s_n^2}{\sigma} + \frac{(k_n - 3)^2}{24} \right\} \sim \chi^2(2) \quad \text{인: 포트왜도, } k_n: \text{포트첨도}$$

$$\text{where } s_n = \frac{\frac{1}{n} \sum_{t=1}^n (e_t - \bar{e})^2}{\left\{ \frac{1}{n} \sum_{t=1}^n (e_t - \bar{e})^2 \right\}^{3/2}}, \quad k_n = \frac{\frac{1}{n} \sum_{t=1}^n (e_t - \bar{e})^2}{\left\{ \frac{1}{n} \sum_{t=1}^n (e_t - \bar{e})^2 \right\}^2}$$

$$\Rightarrow JB \rightarrow 0 \text{ as } data \rightarrow N \text{ dist.}$$

D) 모형 예측


$$-\hat{\sigma}_n^2(1) = \hat{\alpha}_0 + \hat{\alpha}_1 \sigma_n^2 + \dots + \hat{\alpha}_p \sigma_{n+1-p}^2$$

$$-\hat{\sigma}_n^2(2) = \hat{\alpha}_0 + \hat{\alpha}_1 \hat{\sigma}_n^2(1) + \dots + \hat{\alpha}_p \sigma_{n+2-p}^2$$

$$\rightarrow \hat{\sigma}_n^2(l) = \hat{\alpha}_0 + \hat{\alpha}_1 \hat{\sigma}_n^2(l-1) + \hat{\alpha}_2 \hat{\sigma}_n^2(l-2) + \dots + \hat{\alpha}_p \hat{\sigma}_n^2(l-p)$$

$$= \sigma_{n+l-i}^2 \text{ when } l-i \leq 0$$

가설 $H_0: \text{ARCH 효과가 없다 vs } H_1: \text{not } H_0$



(f) 제곱수익률 ACF, PACF 을 봐서도 자기상관여부 관찰 가능

그 외 제곱 잔차나 제곱된 자료의 B-J stat. 이용해 ARCH효과 검정 $\rightarrow$ M-L test

$\rightarrow$ 시계열의 등, 이분산 여부를 파악하고 이분산인 경우 이에 알맞은 모형을 고려

2. GARCH 모형 $AR \rightarrow ARMA \sim ARCH \rightarrow GARCH$

- (+) : p 카질수록 유용

- GARCH (1,1) : $r_t = \sigma_t \varepsilon_t$, $\varepsilon_t \stackrel{iid}{\sim} N(0,1)$

$$\sigma_t^2 = \alpha_0 + \alpha_1 r_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

ARCH와의 차이점 : 과거물산에 영향받음

$$(\alpha_0 > 0, \alpha_1 \geq 0, \beta_1 \geq 0, \alpha_1 + \beta_1 < 1, \forall_i > 0)$$

$$\text{여기서 } \{r_t\} \sim GARCH(1,1) \iff \{r_t^2\} \sim ARMA(1,1)$$

8.2.1. GARCH(1,1)의 성질

① (상동 모형)

1. $E[r_t] = 0, \forall t$

2. $Var(\sigma_t) = \frac{\alpha_0}{(1-\alpha_1-\beta_1)}$

3. $0 \leq \alpha_1 + \beta_1 < 1$ ($\because Var(\sigma_t) > 0$)

4. $m_4 = E[\sigma_t^4] = \frac{3\alpha_0^2(1+\alpha_1+\beta_1)}{(1-\alpha_1-\beta_1)(1-(\alpha_1+\beta_1)^2-2\alpha_1^2)} > 0$

5. $K = \frac{3[1-(\alpha_1+\beta_1)^2]}{1-(\alpha_1+\beta_1)^2-2\alpha_1^2} > 3$

6. 정상성 조건 $\sum_i \alpha_i + \sum_j \beta_j < 1$

② $\{\sigma_t\} \sim GARCH(1,1) \longrightarrow \{\sigma_t^2\} \sim ARMA(1,1)$

$$\{\sigma_t^2\} \text{의 } \begin{cases} \text{ACF : } \rho_{\sigma^2}(h) = \begin{cases} 1 & (h=0) \\ \frac{\alpha_1(1-\alpha_1-\beta_1-\beta_1^2)}{1-\beta_1^2-2\alpha_1\beta_1} (\alpha_1+\beta_1)^{h-1} & (h=1,2,\dots) \end{cases} \end{cases}$$

$$\text{PACF : } \phi_{11} = \frac{\beta_1}{1+\beta_1^2} \neq 0, \phi_{22} = \frac{\beta_1}{1+\beta_1^2+\beta_1^4} \neq 0, \dots$$

$\therefore \text{Def 8.2) } r_t = \sigma_t \varepsilon_t, \varepsilon_t \stackrel{iid}{\sim} N(0,1)$) — ①

$$\sigma_t^2 = \alpha_0 + \sum_i \alpha_i \sigma_{t-i}^2 + \sum_j \beta_j \sigma_{t-j}^2$$

$$(\text{단, } \alpha_0 > 0, \alpha_i \geq 0, \beta_j \geq 0, \sum \alpha_i + \sum \beta_j < 1, \forall_i > 0)$$

$$\text{을 만족하면 } \{r_t\} \sim GARCH(p,q)$$

$$\longrightarrow \{r_t^2\} \sim ARMA(m,q) \quad (m = \max(p,q))$$

8.2.2. GARCH 추정 절차 : ARCH와 비슷 BUT 더 복잡

설정 $\longrightarrow$ 모수 추정 $\longrightarrow$ 모형 진단 $\longrightarrow$ 모형 예측

예측 절차

(quasi) MLE

$\{\varepsilon_t\} \sim \varepsilon, N$ 가정

$$\hat{\sigma}_n^2(1) = \hat{\alpha}_0 + \hat{\alpha}_1 \sigma_n^2 + \hat{\alpha}_2 \sigma_n^2$$

$$\hat{\sigma}_n^2(2) : \text{ @여기서 } \sigma_{t+1}^2 = \alpha_0 + \alpha_1 r_t^2 + \beta_1 \sigma_t^2$$

$$\xrightarrow{r_t^2 = \sigma_t^2 \varepsilon_t^2, \pm \alpha_1 \sigma_t^2} \sigma_{t+1}^2 = \alpha_0 + (\alpha_1 + \beta_1) \sigma_t^2 + \alpha_1 \sigma_t^2 (\varepsilon_t^2 - 1)$$

$$\xrightarrow{t=n+1} \sigma_{n+2}^2 = \alpha_0 + (\alpha_1 + \beta_1) \sigma_{n+1}^2 + \alpha_1 \sigma_{n+1}^2 (\varepsilon_{n+1}^2 - 1)$$

$$\longrightarrow \hat{\sigma}_n^2(2) = \hat{\alpha}_0 + (\hat{\alpha}_1 + \hat{\beta}_1) \hat{\sigma}_n^2(1) \quad (\because E[\varepsilon_{n+1}^2 \dots] = 1)$$

$$\Rightarrow \hat{\sigma}_n^2(l) = \hat{\alpha}_0 + (\hat{\alpha}_1 + \hat{\beta}_1) \hat{\sigma}_n^2(l-1) \quad (l > 1)$$

4. 그 밖의 모형

- GARCH 한계점 : γ 가 양/음이든 σ_t^2 에 미치는 영향이 대칭적

4.1. IGARCH

Def 8.3) $\{X_t\} \sim \text{GARCH}(1,1)$ 일 때

$$\sum_i \alpha_i + \sum_j \beta_j = 1 \text{ 이면}$$

$$\{X_t\} \sim \text{IGARCH}$$

특징) $\{X_t\} \sim \text{GARCH}(p,q)$ 이면 $\text{Var}(X_t) = \frac{\alpha_0}{1 - (\sum \alpha_i + \sum \beta_j)} > 0$
 $= 1$ 이면 $\text{Var} \rightarrow \infty \Rightarrow$ 정상시계열 X

Ex) IGARCH(1,1), $\alpha_1 + \beta_1 = 1$

$$\rightarrow \mathbb{E}[\sigma_{t+1}^2 | F_t] = \mathbb{E}[\alpha_0 + \alpha_1 X_t^2 + \beta_1 \sigma_t^2 | F_t] = \alpha_0 + (\alpha_1 + \beta_1) \sigma_t^2 = \alpha_0 + \sigma_t^2$$

$$\rightarrow \mathbb{E}[\sigma_{t+2}^2 | F_t] = \mathbb{E}[\mathbb{E}[\sigma_{t+2}^2 | F_{t+1}] | F_t] = \mathbb{E}[\mathbb{E}[\sigma_{t+2}^2 | F_t] | F_t] = \mathbb{E}[\alpha_0 + \sigma_{t+1}^2 | F_t]$$

$$= \alpha_0 + \alpha_0 + \sigma_t^2 = 2\alpha_0 + \sigma_t^2$$

$$\Rightarrow \mathbb{E}[\sigma_{t+k}^2 | F_t] = k\alpha_0 + \sigma_t^2$$

$\therefore$ 조건부 분산인 변동성이 지속되는 비정상성이 만들어짐.

4.2. EGARCH : ^{exponential} leverage effect (음의 충격 > 양의 충격) 설명 + 변동의 비대칭적 현상
 Def 8.4) 제약조건 없이 분산값을 양으로 만듦.

$$X_t = \sigma_t \varepsilon_t, \quad \varepsilon_t \stackrel{iid}{\sim} N(0,1)$$

$$\ln \sigma_t^2 = \alpha_0 + \beta_1 \ln \sigma_{t-1}^2 + g(\varepsilon_{t-1}) \quad \text{을 만족하면 } \{X_t\} \sim \text{EGARCH}$$

$$g(\varepsilon_t) = \gamma \varepsilon_t + \delta (|\varepsilon_t| - \mathbb{E}|\varepsilon_t|)$$

여기서 $\varepsilon_t \perp |\varepsilon_t| - \mathbb{E}|\varepsilon_t|$ & 둘은 같은 분포

$$\mathbb{E}[g(\varepsilon_t)] = 0 \text{ 이지만 } g(\varepsilon_t) \text{가 대칭 분포는 X}$$

$$\left\{ \begin{array}{ll} (\gamma + \delta) \varepsilon_t - \delta \mathbb{E}|\varepsilon_t| & (\varepsilon_t \geq 0) \\ (\gamma - \delta) \varepsilon_t - \delta \mathbb{E}|\varepsilon_t| & (\varepsilon_t < 0) \end{array} \right.$$

4.3. GARCH-Mean : $r_t = f(\text{조건부 분산}) \rightarrow \mathbb{E}[r_t]$ 이 시간 따라 변동

Def 8.5)

$$X_t = \mu + \lambda g(\sigma_t^2) + a_t$$

$$a_t = \sigma_t \varepsilon_t$$

$$\sigma_t^2 = \alpha_0 + \sum_i \alpha_i \sigma_{t-i}^2 + \sum_j \beta_j \sigma_{t-j}^2$$

GARCH 평균

$$\mu, \lambda \in \mathbb{R}$$

평균에 대한
변동성계수

을 만족하면 $\{X_t\} \sim \text{GARCH}(p,q)-M$

$$\text{여기서 } g(\sigma_t^2) = \begin{cases} \sigma_t & \text{이다.} \\ \sigma_t^2 \\ \ln \sigma_t^2 \end{cases}$$

If $\lambda > 0$, then risk-premium & high risk-high return.

IX 장. 벡터자기회귀 모형 (Vector Autoregressive, VAR)

Bgnd) 계량경제시계열 예측 모형

1. 단일방정식 회귀모형 : 지금까지 한 거

2. 연립방정식 회귀(구조)모형

i) 60-70, 경제 예측에 이용 (거시론 기본적으로.)

ii) 성공 X { 석유파동 *stagflation* 설명 못
연립방정식 외생변수 사전 선정 어려움

3. ARIMA 모형 (Box-Jenkins)

변수 간 관계를 나타내는 방정식에 관심은 단기보단 *경제적 시계열 그 자체의 통계적 성질*을

분석 : 묵이론 모형

LAGS: AR - forecast a series based *solely* on the past *values* in the series

Errors LAGS: MA - " *solely* " *errors* "

Use both AR & MA terms :
$$Y_t = \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} + \varepsilon_t$$

4. VAR 모형 (1980)

- 별도 외생변수 없이 다수 내생변수 고려

- 단일 AR과 달리 여러 변수 간 상호작용 고려하며 이들 간의 모든 동태적 관계 제공

- 각 1V 의해 설명되는 유도형 형태 방정식 (*reduced form eq.*) 표기 가능

- 동시에 여러 목표변수 예측

- Extension of ARMA into multivariate framework leads to VAR, VMA, VARMA.

0. Overview

- 같은 시점 에서 2개 이상 시계열들로 구성된 다변량 시계열, 즉 벡터시계열을 이용해 *시계열* & *화려* 분석 특징 결합, 시계열 간 나타나는 *선형적 상관관계*와 *동시적 인과관계*를 추정해 예측모형에 이용하는 것이 보다 효과적.

- 활용 : 금융 / 계량경제, Nowadays *역학*, *의학*, *생물학* ~

- ex) 한 나라의 산업생산 변화 추세 $\longleftrightarrow$ 같은 시기 석유가격 변동

한 기간 증가 $\longleftrightarrow$ 같은 기간 외환율 / 이자율 영향

- (+) : ① 외생 / 내생변수 구분 불필요

② 변수들 변화에 따른 다른 변수들의 *영향력* 분석에 용이

③ 모수 추정 시 개별 방정식에 OLS 추정 가능

④ 예측 성능 향상

⑤ 데이터 불포나 근접에 대한 *제한적* 가정 X

- (-) : ① 경제이론 사용 X $\rightarrow$ *정책적 함의* ↓

② 추정과정에서 *자유도 상실*

③ 개별 모수 추정치 대한 해석의 어려움


$\rightarrow$ 인과검정, 충격반응함수, 분산분해 통해 추가 해석 시도

④ 변수 많아질수록 모수 추정 & 추정치 해석 어려움 : ex) k 개 ε_t , 각 ε_t p lags $\Rightarrow k \times p \times k$ 개 모수 추정

⑤ 모형 설정 시 변수 배열순서, 표본기간 / 시차 길이 따라 변수 사이 *과급효과* 대한 분석결과 달라짐

- Hty) 1980 Chris-Jin's Paper, "Macroecon & Reality"
 focused on "empirical econ" than "theoretical econ"

[Idea]



1. VAR 모형의 식별 및 추정 이론

9.1.1. 구조적 (structural) VAR 과 표준적 VAR 모형

- 구조적 VAR :

$$Y_t = \beta_{10} - \beta_{12} X_t + \gamma_{11} Y_{t-1} + \gamma_{12} X_{t-1} + u_{yt}$$

$$X_t = \beta_{20} - \beta_{21} Y_t + \gamma_{21} Y_{t-1} + \gamma_{22} X_{t-1} + u_{xt}$$

(단, Y_t, X_t 는 모두 정상시계열, u_{yt}, u_{xt} 는 NOT correlated 된 WN process)

$$\xrightarrow{\text{행렬}} \begin{pmatrix} 1 & \beta_{12} \\ \beta_{21} & 1 \end{pmatrix} \begin{pmatrix} Y_t \\ X_t \end{pmatrix} = \begin{pmatrix} \beta_{10} \\ \beta_{20} \end{pmatrix} + \begin{pmatrix} \gamma_{11} & \gamma_{12} \\ \gamma_{21} & \gamma_{22} \end{pmatrix} \begin{pmatrix} Y_{t-1} \\ X_{t-1} \end{pmatrix} + \begin{pmatrix} u_{yt} \\ u_{xt} \end{pmatrix}$$

$$\Leftrightarrow B Z_t = \Gamma_0 + \Gamma_1 Z_{t-1} + u_t$$

$$\xrightarrow{\times B^{-1}} Z_t = B^{-1} \Gamma_0 + B^{-1} \Gamma_1 Z_{t-1} + B^{-1} u_t$$

$$= A_0 + A_1 Z_{t-1} + e_t$$

: VAR(1), id VAR, reduced form

9.1.2. 2개의 target var. (dim=2) 인 정상시계열 $Y_{1,t}, Y_{2,t}$ 가진 VAR(1) :

$$Y_{1,t} = \phi_{11} Y_{1,t-1} + \phi_{12} Y_{2,t-1} + \varepsilon_{1,t}$$

$$Y_{2,t} = \phi_{21} Y_{1,t-1} + \phi_{22} Y_{2,t-1} + \varepsilon_{2,t}$$

$$\longrightarrow \vec{Y}_t = \Phi_1 \vec{Y}_{t-1} + \vec{\varepsilon}_t \text{ where } \vec{\varepsilon}_t \sim MVN(\vec{0}, \Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix})$$

$$\xrightarrow{k\text{개 TV}} \vec{Y}_{[t]} = A_1 \vec{Y}_{[t-1]} + \vec{\varepsilon}_{[t]} \text{ where } \vec{\varepsilon}_{[t]} \sim N(0, \Sigma_{[t]})$$

$$\xrightarrow{P\text{로 일반화}} \text{VAR}(p) : \vec{Y}_t = \underbrace{v}_{\in \mathbb{R}^1} + \underbrace{\Phi_1 \vec{Y}_{t-1}}_{K \times K} + \underbrace{\Phi_2 \vec{Y}_{t-2}}_{K \times K} + \dots + \underbrace{\Phi_p \vec{Y}_{t-p}}_{\substack{\in \mathbb{R}^1 \\ K \times 1 \text{ WN w/ } \Sigma_{\vec{\varepsilon}} \text{ non singular}}} + \vec{\varepsilon}_t$$

$$(\vec{Y}_t = (y_{1t}, \dots, y_{kt})'; t \in \mathbb{Z}, \Phi(B) = I - \Phi_1 B' - \dots - \Phi_p B^p \Rightarrow \Phi(B) \vec{T}_t = \vec{\varepsilon}_t)$$

$$\text{Cf) VARMA}(p,q)\text{도 가능} : \vec{Y}_t = v + \Phi_1 \vec{Y}_{t-1} + \Phi_2 \vec{Y}_{t-2} + \dots + \Phi_p \vec{Y}_{t-p} + \vec{\Theta}_1 \vec{\varepsilon}_{t-1} + \vec{\Theta}_2 \vec{\varepsilon}_{t-2} + \dots + \vec{\Theta}_q \vec{\varepsilon}_{t-q} + \vec{\varepsilon}_t$$

9.1.3. 벡터 시계열 및 VAR(1)의 정상성 조건

Def) 약정상성 : 벡터 시계열 $\{\vec{Z}_t\}$ 가

$$1) E[\vec{Z}_t] = \mu$$

$$2) \text{Cov}(\vec{Z}_t, \vec{Z}_{t+h}) = E[(\vec{Z}_t - \mu)(\vec{Z}_{t+h} - \mu)'] = \Gamma(h) : \text{시차 } h\text{에만 의존}$$

를 만족하면 $\{\vec{Z}_t\}$ 는 약정상이다.

$$\text{Cf) } 1. \Gamma(h) \neq \Gamma(-h)$$

$$2. \Gamma(h) = \Gamma'(-h) : \Gamma(h) = E(\vec{Z}_t \vec{Z}_{t+h}') = E(\vec{Z}_{t+h} \vec{Z}_t')' = E(\vec{Z}_t \vec{Z}_{t+h}')' = \Gamma'(-h)$$

(2차원 VAR(1)의) 정상성 조건

$$\vec{Z}_t = \Phi_1 \vec{Z}_{t-1} + \vec{e}_t \quad \text{가 양정상이라 가정하고}$$

$$E[\vec{e}_t] = 0 \rightarrow E[\vec{Z}_t] = \Phi_1 E[\vec{Z}_{t-1}]$$

$$\rightarrow \mu = E[\vec{Z}_t] = (I_k - \Phi_1)^{-1} \text{ 이다.}$$

이 존재하는 non-singular 이어야 하므로

" Φ_1 의 고유값 eigenvalue의 절대값들이 모두 1보다 작아야 한다."

$$\sim \det(I_k - z\Phi_1) \neq 0 \text{ for } \forall \text{ 복소수 } z, |z| \leq 1$$

$$\rightarrow \vec{Z}_t - \mu = \Phi_1 (\vec{Z}_{t-1} - \mu) + \vec{e}_t$$

$$\begin{aligned} \Leftrightarrow \vec{Z}_t^* &= \Phi_1 \vec{Z}_{t-1}^* + \vec{e}_t \\ &= \Phi_1 (\Phi_1 \vec{Z}_{t-2}^* + \vec{e}_{t-1}) + \vec{e}_t \\ &= \dots \end{aligned}$$

$\rightarrow$ VMA(∞)로 표현 가능

9.1.4. VAR 모형 차수 결정과 모수 추정

1. 차수 (p) 결정 : ACF/PACF 이용 : 교차상관관계 존재해 쉽지 X

정보기준

$$\begin{cases} AIC(p) = \ln(|\Sigma_p|) + \frac{2kp}{N} : p \text{ 과 추정 경향} \\ BIC(p) = \ln(|\Sigma_p|) + \frac{k^2 p \ln(N)}{N} : R-제션 JC (Jarvis Criterion)로 출력 \\ HQ(p) = \ln(|\Sigma_p|) + \frac{2k^2 p \ln(\ln N)}{N} : Hannan-Quinn \end{cases}$$

을 최소화 하는 p 선택

2RT

2. 모수 추정 : 각 방정식을 1/ε 이나 MLE 이용해 추정

3. 모형 진단 : 잔차 벡터시계열 $\{\hat{e}_t\}$ 에 자기상관 / 교차상관 존재 확인 (포트만토 검정)

4. 모형 예측 : 단변량 시계열과 동일

개인적으로 중요하다 생각. 한은 paper 에서 많이 보임.
☆☆☆

9.1.5. VAR 에서 (내생) 변수 결정 하는 방법

Bgnd) 벡터시계열은 변수 많으면 상호작용 / 피드백으로 모형 설명/해석이 어려워짐.

→ 최대한 이론에 근거해 변수 결정 : 인과성 검증, 충격-반응 분석, 예측모자 분산분해

1. Granger Causality test

- VAR 장점: 경제변수 간 인과관계 방향 확인하게 함. 즉 VAR(1) 모형 통해 Granger Causality 분석 가능

- Granger, 1969.

"Ceteris Paribus, X_{t-2} 사용함이 X_t 사용할 때보다 Y_t 를 정확하게 예측하면

X_t 가 Y_t 에 영향을 미친다, X_t 가 Y_t 를 Granger cause 한다."

$$- 2차원 VAR(p): \begin{pmatrix} Z_{1t} \\ Z_{2t} \end{pmatrix} = \begin{pmatrix} \phi_{11} & \phi_{12} \\ \phi_{21} & \phi_{22} \end{pmatrix} \begin{pmatrix} Z_{1,t-1} \\ Z_{2,t-1} \end{pmatrix} + \dots + \begin{pmatrix} \phi_{11}^* & \phi_{12}^* \\ \phi_{21}^* & \phi_{22}^* \end{pmatrix} \begin{pmatrix} Z_{1,t-p} \\ Z_{2,t-p} \end{pmatrix} + \begin{pmatrix} a_{1t} \\ a_{2t} \end{pmatrix}$$

에 대해 $H_0: \phi_{12} = \dots = \phi_{12}^* = 0$ 가정

→ 해석: 쌍방향에 대해 가정 $H_0: \phi_{21} = \dots = \phi_{21}^* = 0$

서로 영향을 주지 않을 때 VAR 모형 분석 의미 X

2. IRF: Impulse-Response fun

- VAR 추정계수 바탕으로 모형 내 변수 대해 일정한 크기의 충격을 가할 때 모형의 모든 변수들이 시간의 흐름 따라 어떻게 반응하는지 나타냄

- 구체적으로 IRF는 내생변수의 현재값과 미래값에 대한 오차항 중 하나에 대한 1 std dev. shock 효과를 추적.
즉, 특정변수의 unit shock 이 자기자신 & 나머지 변수에 미치는 영향 관찰.

- 변수 간 상호인과관계 분석하고, 정책변수 변화에 따른 파급효과 분석하는 데 이용됨.

ex) BOK, "Which Monetary Shocks Matter in Small Open Economies? Evidence from VAR,"





Figure 2: Response of Interest Rates Spreads to a 1% Domestic MP Shock



Note: Black broken lines are the 16th and 84th quantiles of the empirical distribution based on 5,000 draws for the U.S.

3. FEVD: Forecast Error Variance decomposition

- 특정시계열의 미래 불확실성에 다른 여러 시계열의 충격이 영향은 줄 수 있음. 단일변수 움직임 대한 설명으로 각 변수 상대적 중요성은 FEVD 통해 평가됨

- 원래 FE는 여러변수들의 충격이 포함되었으므로 요인별 분류는 경제적으로 매우 유용한 정보

- 미래값 예측 + FE를 시계열로 분해한다면 의미에서 VD

- ex) Beaman et al. (2002), "Measuring the Effects of MP: Factor-Augmented VAR Approach"

Table 1. Contribution of the policy shock to variance of the variance decomposition

Variable	Variance Decomposition	R ²
Federal funds rate	0.4535	0.1688
Industrial production	0.0755	0.1075
Consumer price index	0.0441	0.0099
3-month Treasury bill	0.4449	0.0771
Long bond	0.4554	0.0551
Money base	0.0909	0.1019
M2	0.1019	0.0919
Exchange rate (Yen/US\$)	0.2616	0.0557
Commodity price index	0.0759	0.0519
GDP deflator	0.1528	0.1051
Personal consumption	0.0935	0.1079
Domestic consumption	0.0869	0.0619
Non-durable consumption	0.0537	0.0621
Unemployment	0.1265	0.0109
Employment	0.0954	0.1071
Real hourly earnings	0.0965	0.0771
Housing starts	0.0616	0.1071
New orders	0.1281	0.0279
S&P 500 stock index	0.1136	0.1489
Consumer Expectations	0.0518	0.1085

The column entitled "Variance Decomposition" reports the fraction of the variance of the response of the variable to the policy shock, or the 10-month horizon, explained by the policy shock. "R²" refers to the fraction of the variance of the variable explained by the variance of the policy shock (F, T, S). See text for details.
*This is by construction.